



Eötvös Loránd Tudományegyetem

Informatikai Kar

Komputeralgebra Tanszék

Prímszita algoritmusok összehasonlítása

Vatai Emil
Adjunktus

Nagy Péter
Programtervező Informatikus BSc

Budapest, 2018

Tartalomjegyzék

1. Bevezetés	2
2. Felhasználói dokumentáció	3
2.1. A megoldott feladat	3
2.2. Felhasznált módszerek	3
2.2.1. Init és generator program	4
2.2.2. Gui	5
2.3. A program telepítése és futtatása	6
2.4. Prímek keresése	7
2.5. Mintaadatbázis karbantartása	8
2.5.1. Adatbázis információk	9
2.5.2. Szegmensek összesítése	10
2.5.3. Összesítőfájlok összefésülése	10
2.6. Szítatáblák ellenőrzése	11
2.7. Szíták ellenőrzése	11
2.8. Minta megjelenítése	12
2.8.1. Minta hozzáadása	13
2.8.2. Minta közelítése	13
2.9. Szíták mérése szkriptekkel	15
3. Fejlesztői dokumentáció	17
3.1. A feladat leírása	17
3.2. A program komponensei	18
3.3. A forráskód	20
3.3.1. Init és generator	20
3.3.2. Gui	23
3.4. Adatszerkezetek	25
3.5. Numerikus algoritmusok	25
3.6. Szíták	25
3.7. Prioritásos sorok	25
3.7.1. Bináris kupac	26

3.7.2.	Bigyó	26
3.8.	Memória	27
3.9.	Teszt	27
3.9.1.	Adatszerkezetek	27
3.9.2.	Numerikus pontosság és sebesség	27
3.9.3.	Sziták	27
3.9.4.	Elmélet vs. mért	27
4.	Irodalomjegyzék	28

1. fejezet

Bevezetés

Sziták összehasonlítása azonos környezetben. Hatékonyság összehasonlítása az elmélet szerint várható értékekkel. Ellenőrzésként a prímek néhány statisztikájának összevetése az elméleti értékekkel, és az ismert eredményekkel. Hatékonyság és implementálhatóság.

2. fejezet

Felhasználói dokumentáció

2.1. A megoldott feladat

A program lehetővé teszi a prímek néhány statisztikájának ábrázolását grafikonon, és összevetését elméleti becsült értékekkel, valamint néhány különböző szita-algoritmus futási idejének megmérését, és grafikus megjelenítését. A programmal egyéb forrásból származó minták megjelenítése is lehetséges.

A prímszámok statisztikáinak előállításához a programhoz tartozik egy optimalizált szita-implementáció, amivel 2^{64} -ig lehet szitálni, és az eredményt rögzíteni. Az elementett prímlistákat a program egy külön része összesíti több statisztika szerint, és a megjelenítést az összesítések alapján végzi el.

Különböző szita-algoritmusok futási idejének összehasonlításához a program tartalmazza Atkin[1] szitájának egy implementációját, és Eratoszthenész szitájának néhány variációját.

2.2. Felhasznált módszerek

A program két elkülönülő részből áll. A prímszámok statisztikáinak előállításához először szükséges a prímek listájának előállítása. Ehhez egy optimalizált, gyors szita C nyelven készült el. A könnyebb implementálhatóság miatt ez is két külön program, a kis számokat szitáló init, és a nagyobb számokkal dolgozó generator. A két program a működési elvében hasonló.

A program többi része Java nyelven van megírva, ez a gui nevű program. Ez összesíti a prímek listáját, tartalmazza a futási idők összehasonlításához írt szitákat, és jeleníti meg a prímek statisztikáit, és a futási idők mintáit.

A program több prímszítát tartalmaz. A prímszíták számok egy listájáról döntenek el, hogy melyik szám prím, és melyik összetett. A legtöbb implementált szita Eratoszthenész szitájának variációja. Eratoszthenész szitája az egész számok egy

adott $[2, n]$ intervallumába eső számokról dönti el, hogy melyik prím. Ezt a pq szorzatra bontható számok megjelölésével teszi, ahol a $p < n$ prím, és $1 < q \in \mathbb{N}$. Az algoritmus sorban veszi a számokat a listában kettőtől. Ha egy addig még meg nem jelölt számot talál, akkor az prím, és a listában megjelöli annak többszöröseit, de a prímet nem. Az algoritmus futása után a meg nem jelölt számok a prímek.

```

1: n: a szitálás felső határa
2: a számok legyenek nem megjelölve, 2-től  $n$ -ig
3: for  $i \leftarrow 2, i \leq n, i \leftarrow i + 1$  do
4:   if  $i$  nincs megjelölve then
5:     for  $j \leftarrow 2i, j \leq n, j \leftarrow j + i$  do
6:       legyen  $j$  megjelölve
7:     end for
8:   end if
9: end for

```

Ennek az egyszerű algoritmusnak a legnagyobb hátránya, hogy n -ig szitálva $n - 1$ bit memóriára van szüksége, ez a bitvektor a szitatábla. Erre megoldás a szegmentált szitálás, ahol egy rövidebb, nem feltétlenül 2-től kezdődő intervallumban szitálnak. Ehhez szükség van a prímek listájára, legalább az intervallum végének négyzetgyökéig.

A legegyszerűbb szegmentált szita egy szegmens szitáláshoz minden prímet sorban vesz, osztással meghatározza, hogy melyik a legkisebb többszöröse a szegmensben, ha van ilyen szám, majd onnantól összeadással szitál a szegmens végéig, ahogy Eratoszthenész szitája is teszi.

Több, egymás utáni szegmens szitálásával az osztás költsége több szegmensre szétosztható, ha a szita a minden prímről minden szegmens szitálása után megjegyzi, hogy melyik számot szitálna, ami már nagyobb, mint a szegmens vége. A következő szegmens feldolgozásakor a prímmel innen lehet folytatni a szitálást. A módszer hátránya, hogy ehhez el kell tárolni ezeket a prím-pozíció párokat, ennek tárigénye nagyságrendileg $\mathcal{O}(\sqrt{n})$, ha legnagyobb szitált szám n . A hatékony eratoszthenészi sziták ennek a prím-pozíció listának csak azon elemeit veszik figyelembe egy szegmens szitálásakor, amik ténylegesen szitálnak is a szegmensben.

2.2.1. Init és generator program

A prímszámok listájának generátora C nyelven készült el. A program csak parancsorból futtatható, és a sztenderd könyvtári függvényekből is csak néhányat használ a memóriájában előállított eredmények fájlba írásához. A C nyelv választását a hatékony végrehajtás és memóriafelhasználás, és a hordozhatóság indokolja, a generátor elkülönítését az automatizálhatóság indokolja.

A prímgenerátor Eratoszthenész szitájának szegmentált változata, a szitatábla egy 2^{30} hosszú darabját szitálja ki minden iterációban. A generátor önmaga is két részből áll. Egy egyszerűbb implementáció a prímek listáját 2^{32} -ig állítja elő. Ez az első 4 szegmens nem csak a statisztikákhoz szükséges, a generátor, és a Java program szitái is használja, amikor a szitalás intervalluma 1-nél nagyobb számtól kezdődik.

A gyorsabb, de összetettebb szita 2^{32} -től $2^{64} - 2^{34}$ -ig szital, és a futásához szükséges a prímek listája 2^{32} -ig. A szitatáblát a memóriában a gyorsítótár hatékonyabb a kihasználásához kisebb részszegegmentekre osztja, és a prímekeket a nagyságuk és a következő szitalási pozíciójuk szerint csoportosítja. Továbbá nagyobb prímeknek csak harminccal relatív prím többszöröseit veszi figyelembe.

2.2.2. Gui

A program többi része a Java környezethez készült. A minták és függvények ábrázolásához használt Swing grafikus könyvtár a Java környezet része, egyszerű, hordozható, támogatja az élsimítást, és a sebessége elfogadható a feladatra. A Java sztenderd konténerosztályai habár kényelmesen használhatóak, és változatosak, de sebesség és memóriakihasználtsági problémák miatt több helyen is alacsonyabb szintű megoldást kellett választani.

A program a mintákat alapfüggvények lineáris kombinációjával képes közelíteni, a legkisebb négyzetek módszerével. A minták elemeinek nagy száma, és a mintaértékek nagy terjedelme miatt szükséges volt a numerikus algoritmusok nagyobb pontosságú implementációja, ami a számítási idő növekedésével jár.

A program hosszabb távon egyedül a prímek szegmensenkénti statisztikáit tárolja, amit csak sorban dolgoz fel, és a statisztikák összmérete sem indokolna egy egyszerű bináris fájlnál bonyolultabb megoldást. Az adatvesztés elkerüléséhez elég a statisztikafájl csere alapú felülírása.

A Java program tartalmaz több prímszita implementációt is, ezeknek az algoritmikus bonyolultsága különböző, de a futási idejük összehasonlíthatóságához a közös részek közös implementációt kaptak, és az eltérő részek hasonló szinten optimalizáltak. A sziták helyességének ellenőrzéséhez a sziták eredménye egymással összehasonlítható.

A programhoz elkészült Eratoszthenész szitájának több variációja, mindegyik szegmentáltan működik, a különbség a prímek listájának kezelésében van. A legegyszerűbb implementált eratoszthenészi szita a prímek listáját minden szegmensben végig bejárja. A prioritásos soron alapuló sziták a prímekeket részlegesen rendezik az alapján, hogy hány szegmensnyire van az éppen szitalt szegmenstől a prím következő többszöröse, a sor elejétől eltávolítják a szegmensben szitaló prímekeket, és

az új pozíciójukkal a sorba visszahelyezik. Ilyen a bináris kupacot, és az edénysort használó szita.

A **cache optimized linear sieve**[2] a prímeket teljesen rendezi az alapján, hogy legközelebb melyik szegmensben fognak szitálni, és a prímelek nagyság szerinti csoportosításával a rendezés fenntartásához az elemek memóriabeli mozgatását is kerüli.

Atkin szitája[1] az előbbi algoritmusoktól jelentősen eltér, a prímelek többszöröse helyett $n = ax^2 + by^2$ egyenlet megoldásait keresi egy n szám vizsgálatához, x és y pozitív egészek befutásával, a és b egész konstansok. A pontos kvadratikusan formát, és x és y lehetséges értékeit Atkin az egészek algebrai bővítésével határozza meg, $n \in 4\mathbb{Z} + 1$ esetén a Gauss-egészek, $n \in 6\mathbb{Z} + 1$ esetén az Eisenstein-egészek, és $n \in 12\mathbb{Z} + 11$ esetén a $\mathbb{Z}[\sqrt{3}]$ segítségével.

A sziták között kapott helyet a próbaosztás, és az erős pszeudoprím teszt is, de ezek a lassúságuk miatt csak igen rövid tartományokon használhatóak. A próbaosztás egy faktorizációs eljárás, ami egyetlen számot nem-triviális szorzatra próbál bontani. Az (erős) pszeudoprím teszt egy prímteszt, egyetlen számról próbálja eldönteni, hogy az prím-e. A prímteszteket általában több nagyságrenddel nagyobb számokra alkalmazzák, mint a szitákat, és teljes módszer helyett sokszor megelégednek egy valószínűségi válasszal.

2.3. A program telepítése és futtatása

A program futtatásához Windows vagy Linux operációs rendszer szükséges, legalább 4GB szabad memóriával. A Java program futtatásához JRE8 szükséges, a fordításához JDK8. A C program fordításához C99 szabványú fordítóprogram kell. A program fejlesztése és tesztelése OpenJDK8-cal és GCC 7.3-mal történt Linux operációs rendszeren.

A CD mellékleten található tarball a Java programot lefordítva is tartalmazza, kicsomagolás után azonnal futtatható. A C programot a generator könyvtárban található Makefile segítségével lehet lefordítani:

```
generator$ make clean build
```

A Java program a NetBeans 8-as verziójával készült, parancssorból a project ant fájljának segítségével lehet újrafordítani:

```
gui$ ant clean jar
```

A program futtatásához több előkészített script is rendelkezésre áll, ezeket mind a scripts könyvtárból lehet indítani. Az előző két fordítást egyben is el lehet végezni a recompile scripttel:

```
scripts$ ./recompile
```


2.4. Prímek keresése

A prímek keresését két program végzi, az init program 2^{32} -ig keresi meg és tárolja el a prímekeket, a generator 2^{32} -től $2^{64}-2^{43}$ -ig. Az init készítette szitattáblák a generator futásához szükségesek.

Mindkét program a számokat 2^{30} hosszú táblánkként szitálja, minden tábla első száma $2^{30}k+1$ alakú. A szitattáblában csak a páratlan számok vannak nyilvántartva. A szitattáblákat a programok a fájlrendszerben bitvektorként tárolják, egy tábla kb. 64Mb.

Az első négymilliárd szám szitálása a következő képpen indítható el:

```
generator$ ./init.bin ../db
szegmens 0 - kezdet 1 - felkészülés 159 906 063 ns - szitálás 1 122 878 403 ns
szegmens 1 - kezdet 1 073 741 825 - felkészülés 2 353 698 ns - szitálás 1 171 101 336 ns
szegmens 2 - kezdet 2 147 483 649 - felkészülés 2 344 515 ns - szitálás 1 188 330 478 ns
szegmens 3 - kezdet 3 221 225 473 - felkészülés 2 391 660 ns - szitálás 1 199 900 603 ns
```

Ennek eredmény 4 bittérkép-fájl, amit a db mappába ment.

A generator programot több féle képpen is lehet indítani. Mindegyik esetben két paramétert kell megadni az indításhoz, a számot, ahol szitálást kezdje, és a szegmensek számát, amit ebben a futásban végig kell szitálni. A kezdő számot meg lehet adni decimálisan is, vagy hexadecimálisan is, "0x" prefixszel. A szegmensek számát is kétféle képpen lehet szabályozni. Az egyik lehetőség fix számú szegmens megadása, decimálisan, vagy hexadecimálisan.

```
generator$ ./generator.bin ../db start 0x100000001 segments 3
szegmens kezdet: 4 294 967 297
szegmensek száma: 3
kis szegmensek mérete: 22
elágazások bitjei: 8
felkészülés 1/4
felkészülés 2/4
felkészülés 3/4
felkészülés 4/4
felkészülés vége
szegmens 4 - kezdet 4 294 967 297 - felkészülés 8 162 031 487 ns - szitálás 729 914 370 ns
szegmens 5 - kezdet 5 368 709 121 - felkészülés 418 ns - szitálás 736 412 117 ns
szegmens 6 - kezdet 6 442 450 945 - felkészülés 385 ns - szitálás 750 022 409 ns
összes szitálás 2 216 348 896 ns
```

A másik mód a háttértáron fenntartandó szabad hely átadása, decimálisan, vagy "0x" prefixszel hexadecimálisan. Ekkor következő szegmens szitálása előtt megvizsgálja, hogy van-e még annyi szabad hely az adatbáziskönyvtárban, mint amennyi meg van adva, ha igen, akkor szitálja a szegmenst, és lép a következőre, és ha nincs már elég szabad hely, akkor a program megáll.

```
generator$ ./generator.bin ../db start 0x100000001 reserve-space 1000000000
szegmens kezdet: 4 294 967 297
fenntartandó hely: 1 000 000 000 byte
kis szegmensek mérete: 22
elágazások bitjei: 8
felkészülés 1/4
felkészülés 2/4
felkészülés 3/4
felkészülés 4/4
felkészülés vége
szegmens 4 - kezdet 4 294 967 297 - felkészülés 8 162 031 487 ns - szitálás 729 914 370 ns
szegmens 5 - kezdet 5 368 709 121 - felkészülés 418 ns - szitálás 736 412 117 ns
szegmens 6 - kezdet 6 442 450 945 - felkészülés 385 ns - szitálás 750 022 409 ns
összes szitálás 2 216 348 896 ns
```

Mindkét program kimenetében a *start* a szegmens kezdőszáma, a *segment* az indexe, $start = segment \cdot 2^{30} + 1$, az *init* a szita inicializálási ideje a szitálás előtt, és a *sieve* a szegmens szitálásának ideje. Ezek az információk az elmentett táblafájlokból is kiolvashatóak.

2.5. Mintaadatbázis karbantartása

A mintaadatbázis a lementett szitatáblák összesített statisztikáit tárolja. A programok az adatbázis könyvtárában kétfajta fájlt vesznek figyelembe. A `"primes\[0-9a-f]\{16\}"` reguláris kifejezésnek megfelelő nevű fájlok a szegmens szitatáblái. A fájlnev második fele a szegmens kezdőszáma hexadecimálisan. A fájl a páratlan számok bittérképe mellett tartalmazza a szegmens szitálásának megkezdésére, és a szitálására fordított időt, valamint ellenőrzésképpen a szegmens kezdőszámát is.

A szitatáblák mellett az adatbázis tartalmazhatja szegmensök összesített statisztikáit is, "aggregates" néven. Ez a fájl az eddig összesített szegmensekről a következő információkat tartja nyilván, minden szegmensről külön-külön:

- a szegmens kezdőszáma
- a szegmens szitálására való felkészülés idejét
- a szegmens szitálásának idejét
- az összesítésre fordított időt
- a szegmensfájl utolsó módosítási idejét
- a szegmensbe eső legkisebb, és legnagyobb prímet
- a szegmensbe eső prímek számát, $12\mathbb{Z} + 11$, $4\mathbb{Z} + 1$, $4\mathbb{Z} + 3$, $6\mathbb{Z} + 1$ alakok szerinti bontásban
- a szegmensben előforduló prímhézagok első előfordulásának helyét, és az előfordulások számát.

Példaként ha a szegmens mérete 16 szám lenne, és 17-től szitálnánk egy szegmens, akkor a szegmensfájl leírná, hogy a prímek 17, 19, 23, 29, 31, és az összetett számok 15, 21, 25, 27. A szegmens összesítése

- a szegmens 17-tel kezdődik
- a legkisebb prím 17, a legnagyobb 31
- a szegmensben 5 darab prím van, ebből 2db $4\mathbb{Z} + 1$, 3db $4\mathbb{Z} + 3$, 2db $6\mathbb{Z} + 1$, és 1db $12\mathbb{Z} + 11$ alakú

- a szegmensben előforduló prímhézagok
 - 2 (ikerprímek) kétszer fordul elő, először 17-nél
 - 4 egyszer fordul elő, először 19-nél
 - 6 egyszer fordul elő, először 23-nál

lenne.

Az adatbázison három művelet végezhető:

- Le lehet kérni, hogy
 - a szegmensfájlok száma
 - az első és utolsó szegmensfájl
 - az legkisebb hiányzó szegmensfájl
 - a szegmensstatisztikák száma
 - az első és utolsó szegmensstatisztika
 - az legkisebb hiányzó szegmensstatisztika
 - van-e szegmensfájl, ami nincs összesítve
- Összesíteni lehet az új szegmensfájlokat.
- Össze lehet fésülni két összesítőfájlt.

Mindhárom művelet elvégezhető grafikus felületen, és automatizáláshoz parancssorból is. A grafikus felületet a gui scripttel lehet indítani, a parancssorból a database script segítségével lehet elérni a műveleteket.

Ezek a scriptek határozzák meg, hogy a program melyik könyvtárat használja adatbázisként, ezt nem kell külön megadni. Szükség esetén ez a könyvtár a scriptek egyszerű módosításával megváltoztatható.

2.5.1. Adatbázis információk

A adatbázis információkat a grafikus felületen a "DB info" gomb megnyomásával lehet lekérdezni, parancssorból a "database info" kiadásával.

```
scripts$ ./database info
100.0%
szegmensfájlok: szegmensek száma: 7
szegmensfájlok: első szegmens kezdete: 1
szegmensfájlok: utolsó szegmens kezdete: 6,442,450,945
szegmensfájlok: első hiányzó szegmens kezdete: 7,516,192,769
szegmensfájlok: hiányzó szegmensek száma: 18,446,744,073,709,551,593

összesítések: szegmensek száma: 62,881
összesítések: első szegmens kezdete: 1
összesítések: utolsó szegmens kezdete: 67,516,885,893,121
összesítések: első hiányzó szegmens kezdete: 67,517,959,634,945
összesítések: hiányzó szegmensek száma: 18,446,744,073,709,488,719
```

```

új szegmensfájlok: 7

scripts$ ./database info crunch 100
100.0%
szegmensfájlok: szegmensek száma: 7
szegmensfájlok: első szegmens kezdete: 1
szegmensfájlok: utolsó szegmens kezdete: 6,442,450,945
szegmensfájlok: első hiányzó szegmens kezdete: 7,516,192,769
szegmensfájlok: hiányzó szegmensek száma: 18,446,744,073,709,551,593

összesítések: szegmensek száma: 62,881
összesítések: első szegmens kezdete: 1
összesítések: utolsó szegmens kezdete: 67,516,885,893,121
összesítések: első hiányzó szegmens kezdete: 67,517,959,634,945
összesítések: hiányzó szegmensek száma: 18,446,744,073,709,488,719

crunch: ../generator/generator.bin ../db start 0x3d6840000001 segments 0x64

```

A "crunch" utótag és szitálni kívánt szegmensek számának megadásával az utolsó sorban a következő futtatásra ajánlott parancsot is megjeleníti a program. Ezeknek a parancsoknak a követésével a teljes szitálható tartományt fel lehetne dolgozni. A "crunch-numbers" script ezt a feladatot kíséri meg elvégezni.

Az info megjeleníti az új szegmensfájlok számát is, azokat, amikhez vagy nem tartozik összesített adat, vagy tartozik, de az ott tárolt utolsó módosításnál újabb a szegmensfájl.

2.5.2. Szegmensek összesítése

Az adatbázis könyvtárban található új szegmensfájlokat a "DB összesítés" gomb megnyomásával, vagy a "database reaggregate" paranccsal lehet összesíteni. Minden olyan szegmensfájlról új összesítés készül, amihez még nem tartozott összesítés, vagy a szegmensfájl újabb, mint ami alapján a már meglévő összesítés készült. Az adatbázisban már meglévő, többi szegmenshez tartozó statisztika nem vész el.

```

scripts$ ./database reaggregate
100.0%

```

2.5.3. Összesítőfájlok összefésülése

Lehetőség van egy másik adatbázisból statisztikák átvételére is. Erre több gépen párhuzamosan szitálva lehet szükség. Az összefésülést a grafikus felületen a "DB import" megnyomása után egy file kiválasztásával lehet indítani, parancssorból a "database import aggregates fájlnev" kiadásával. A megadott fájlból azokat a szegmeneseket veszi át a program, amik vagy nincsenek még meg az adatbázisban, vagy megvannak, de az importált statisztikák utolsó módosítási ideje nagyobb az adatbázisban lévőnél.

```

scripts$ ./database import aggregates ../db/aggregates.large
100.0%

```

screenshot

2.6. Szitatáblák ellenőrzése

A generator program teszteléséhez a grafikus program képes a szegmensfájlok ellenőrzésére. Ehhez a program újra előállítja az ellenőrzött szegmensfájlokat, és azokat összeveti. Az összevetéshez az egyszerű szegmentált eratoszthenészi szitát, vagy ez erős pszeudoprím tesztet lehet választani. A pszeudoprím teszt rendkívül lassú, a célja, hogy a szitákhoz képest egy alapvetően más módszer is rendelkezésre álljon az ellenőrzéshez.

A grafikus felületen a "Szegmensfájlok ellenőrzése" gomb megnyomása után lehet kiválasztani a szitálni kívánt szegmenseket, és a referencia előállításának módszerét, majd az "Ellenőrzés" gombbal lehet megkezdeni a tényleges folyamatot.

Az ellenőrzést parancssorból is lehet futtatni a check-segments szkripttel. A szkript első paraméterében a referencia módszerét várja, ami lehet "sieve", vagy "test", a paraméterek maradéka az ellenőrizendő szegmensek kezdőszáma kell legyen. Ha egy kezdet sincs megadva, akkor a program az adatbázis könyvtárban található összes szegmensfájlt ellenőrzi.

```
scripts$ ./check-segments sieve
100.0%: A szegmensek helyesek.

scripts$ ./check-segments sieve 0x1 0xc0000001
100.0%: A szegmensek helyesek.

scripts$ ./check-segments test 0x1
100.0%: A szegmensek helyesek.
```

Ha a kezdőszám nagyobb, mint 1, a szitával ellenőrzéshez szükséges, hogy az init program által előállított négy darab szegmensfájlt tartalmazza az adatbáziskönyvtár, mert a szita kezdőszámra pozícionálásához a prímszámokat innen olvassa fel a program.

[screenshot](#)

2.7. Sziták ellenőrzése

Az sebességek összehasonlításához írt sziták eredményét is lehet ellenőrizni, az összehasonlításához itt is a szegmensek ellenőrzésénél használt egyszerű szegmentált szita a referencia.

A program grafikus felületén a "Sziták ellenőrzése" lehetőséget választva ki kell választani az ellenőrizendő szitát, és az ellenőrizni kívánt intervallum kezdő és végző számát. A folyamat az "Ellenőrzés" gomb megnyomásával indítható.

Parancssorból is ellenőrizhetők a sziták a "check-sieve" szkripttel. A script 3 paramétere a szita neve, és az intervallum kezdő-, és végszáma. Az ellenőrizhető sziták nevei:

- atkin: Atkin szitája[1]

- cols: [Cache optimized linear sieve](#)^[2]
- eratosthenes-segmented: Eratoszthenész szitájának szegmentált változata
- bin-heap és bin-heap-inplace: Eratoszthenész szitája bináris kupaccal, az bin-heap-inplace a kupac javítását helyben végzi
- buckets, buckets-n, buckets-simple: Eratoszthenész szitája, edénysorral
a buckets-simple nem szegmentált, a buckets, és a buckets-n szegmentált. a buckets-n -ben az n helyére 1-től 8-ig a számrendszer bitjeit lehet megadni, pl. buckets-3 8as számrendszerben számol
- trial-division: próbaosztás

A "Sziták" fejezetben található ezeknek a szitáknak a részletesebb leírása.

A sziták nevei listázhatóak a list-sieves scripttel, a describe-sieves script rövid leírást is ad.

```
scripts$ ./check-sieve buckets -3 30000000000001 30100000000001
100.0%: A szita helyes.
```

Ha a kezdőszám nagyobb, mint egy, az ellenőrzéshez ilyenkor is szükséges, hogy a négy darab kezdő szegmensfájlt tartalmazza az adatbáziskönyvtár.

[screenshot](#)

2.8. Minta megjelenítése

A program a grafikus felületén képes mintákat ábrázolni, a mintákat függvényekkel közelíteni, és ezeket a függvényeket is ábrázolni, valamint kiszámolja a közelítések négyzetes hibáját a mintához képest. A program egyváltozós, egyértékű mintákat kezel, azok között is a természetes számokhoz valós számokat rendelőket. A minta akár külső forrásból is származhat.

A grafikonábrázoló részt a gui-graph scripttel lehet indítani, vagy a gui scripttel, majd a "Grafikon" gomb megnyomásával.

Az ablak bal oldalán jelennek meg a betöltött minták és közelítő függvények grafikonjai. Minta és függvény hozzáadása után a grafikon megjelenített részét a program úgy választja meg, hogy minden minta összes pontja ebbe a nézetbe essen. A nézet a grafikon feletti gombokkal, vagy egérrel mozgatható, nagyítható, vagy kicsinyíthető. Az "Auto.nézet" gombbal a nézet a minták teljes terjedelmére visszaállítható.

Az ablak jobb oldala a betöltött minták kezelésére szolgál. A felső harmada az összes betöltött mintát mutatja. Az ablak jobb oldalának alsó két harmadában az itt kiválasztott minta részletei látszódnak.

2.8.1. Minta hozzáadása

A "Minta hozzáadásánál" három adatforrásból lehet választani. A "Fájl betöltésével" CSV fájl olvasható be. A fájl formátuma megengedő, az első oszlopot x, a második oszlopot y értékeknek próbálja értelmezni, a fel nem ismert sorokat eldobja. Ha az első sor első oszlopa "BARS", akkor vonaldiagram helyett a mintát oszlopdiagramként fogja ábrázolni.

A "Prímstatisztikák" a generator kimeneteléből összesített statisztikák, amiket az adatbáziskönyvtárban keres. A program a szegmensstatisztikák hiánytalan kezdőszeletét veszi csak figyelembe. A statisztikáknak három csoportja van. A prímek száma, és néhány kiemelt alakú prím száma a szegmensek végén. Ide tartozik ugyanezen a helyeken a prímszámtétel becslése, és a becslés abszolút és relatív hibája is. A prímhézagok statisztikái a szegmensek teljes kezdőszeletére vonatkozik. Ezek az előfordult hézagok gyakorisága, első előfordulása, jósága, és az legnagyobb prímhézag adott számig. Ezeken kívül a szegmensek szitálásának ideje is betölthető. Az összesített idő a szegmensek végig az összes addigi szegmens összes ideje, a szegmensenkénti a szegmensek végéhez az adott szegmens szitálásának idejét rendeli.

A minták harmadik forrása a programba épített sziták futási idejének mérése. Ehhez meg kell adni a szitát, a szitált intervallum elejét és végét, a szita belső szegmensméretét, a generálandó minták számát, és a mérések számát, a mértéket, és hogy az eredményt összesítse-e. A sziták listája ugyanaz, mint a sziták ellenőrzésénél. A mintákat a program a szitált intervallumon egyenletesen osztja el a megadott méretű szegmensek határainál. A teljes szitálást a megadott mérések számánszor végzi el, és az eredményt átlagolja. Összesítést kiválasztva a minta értéke a szitált intervallum elejétől az adott számig szitálás teljes ideje, különben az előző minta helyétől. A mérték szabályozza, hogy a tényleges eltelt időt mérje a program nanoszekundumban, vagy az elvégzett műveletek számát.

screenshot

2.8.2. Minta közelítése

Az ablak jobb oldalának középső harmadában a kiválasztott minta részletei látszódnak. Itt változtatható meg a minta ábrázolásához használt szín, távolítható el a minta, vagy menthető CSV fájlba.

A táblázat a minta közelítéseit mutatja, itt olvashatóak le a közelítés komponensfüggvényei, és a közelítés hibája. A "Közelítés" gombbal lehet új közelítést hozzáadni az ábrázoláshoz. A közelítéshez a lineáris legkisebb négyzetek módszerét használja a program, ehhez a lineáris kombináció elemi függvényeit meg kell adni. A függvények kiválaszthatóak az előre megadott listából, vagy javascript nyelven is megadhatóak. A közelítéshez csak olyan függvények használhatóak, amik a minta

minden pontjában értelmezve vannak.

Javascript függvényhez meg kell adni a függvény nevét és forráskódját. A forráskódban a függvény argumentumára az x változóval lehet hivatkozni, és a script utolsó kifejezésének értéke lesz a függvény értéke x -ben. Pl. az $x \mapsto \frac{\ln x}{x}$ hozzárendelés forráskódja:

```
Math.log(x)/x
```

A scriptben használható változó, és a szokásos vezérlőutasítások. Pl. az iterált logaritmus egy megadása:

```
var y=0;
while (1<x) {
  x=Math.log(x);
  ++y;
}
y
```

Az így megadott függvények visszatérési értéke mindig double kell legyen, és a függvény azokban a pontokban értelmezett, ahol ez az érték véges.

Egy kiválasztott közelítés részletei az ablak jobb alsó sarkában látszódnak, itt megváltoztatható a közelítéshez rendelt szín, és eltávolítható a közelítés. A táblázat a közelítéshez kiválasztott függvények együtthatóit mutatja a lineáris kombinációban.

A legkisebb négyzetek módszerének komponensei röviden leírhatóak. Ha az n elemű minta $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ ($x_i, y_i \in \mathbb{R}$), a közelítéshez kiválasztott m függvény f_1, f_2, \dots, f_m ($f_i : \mathbb{R} \mapsto \mathbb{R}$), akkor a legkisebb négyzetek módszere keresi azokat a c_1, c_2, \dots, c_m ($c_i \in \mathbb{R}$) skalárokat, hogy az

$$f(x) = \sum_{i=1}^m c_i f_i(x) (x \in \mathbb{R})$$

közelítő függvény és a minta eltérése minimális legyen a

$$\sum_{i=1}^n (f(x_i) - y_i)^2$$

négyzetes eltérés összeg szerint.

A program ezt az eltérés összeget jeleníti meg a közelítés hibájaként, valamint a c_i skalárok a közelítés elemi függvényeinek együtthatói.

screenshot

2.9. Sziták mérése szkriptekkel

A sziták futási idejének mintáit parancssorból is elő lehet állítani a measure-sieve szkripttel, paraméterként meg kell adni ebben a sorrendben:

- a szita nevét, ezek ugyan azok lehetnek, mint a check-sieve szkriptnél
- a számot, ahol a szitálás kezdődik, ez páratlan szám kell legyen
- a szitálás végét, ez páratlan szám kell legyen
- a szegmensek méretét
- a mérések számát
- a minták számát
- hogy időt (nanosecs), vagy műveleteket (operations) mérjen
- összesítse az időket ("sum"), vagy szegmensenként külön számolja ("segment")
- a fájlt, ahova az eredményt mentse CSV-ben

A számokat meg lehet adni decimálisan, és hexadecimálisan is "0x" előtaggal. Ha a kezdőszám nagyobb, mint 1, akkor az adatbáziskönyvtárnak tartalmaznia kell az init program generálta első négy szegmenst.

Lehetőség van a mérték és az összesítés mind a négy kombinációját egy méréssel előállítani, ehhez mind a négy kimeneti fájl meg kell adni külön.

```
scripts$ ./measure-sieve buckets-3 1 0x10000001 0x10000 3 1000 nanosecs sum out1.csv
100.0%
scripts$ ./measure-sieve buckets-3 1 0x10000001 0x10000 3 1000 operations segment out2.csv
100.0%
scripts$ ./measure-sieve buckets-3 1 0x10000001 0x10000 3 1000
seg-ns.csv seg-ops.csv sum-ns.csv sum-ops.csv
100.0%
```

A mérések megkönnyítéséhez a measure-sieves szkript az összes szitát megméri, és az eredményt a samples könyvtárba menti. A samples könyvtárban a mérési eredmények 4 külön könyvtárban szegmensenként/összesítve, és idő/művelet szerinti bontásban vannak. Ezekben a könyvtárakban 2 fajta mérés eredményei vannak. Az atkin könyvtárban Atkin szitájának sebessége van megmérve különböző szegmensméretek esetén. A speed kezdetű könyvtárakban az összes szita sebességének mérése található, 2^{20} szegmensmérettel. A könyvtárak nevében a szám a szitálás kezdetét adja meg, a speed n könyvtárban a mérések $2^n + 1$ -től kezdődnek. A lassabb szitákat csak kisebb nagyságrendekre méri meg a szkript, ezek futási ideje hamar túl nagyává válik.

A measure-generator szkript a generator program sebességét méri meg, 3 változóban. A szitálás kezdetének nagyságrendjén kívül a szegmensméretet, és az edénysor

számrendszerét is variálja. Az eredményt a samples/measure-generator.csv fájlba menti, ez nem használható a program mintamegjelenítésével, mert az egy változós mintákkal dolgozik. Ennek a mérésnek a célja az, hogy a generator program paramétereit egy konkrét számítógéphez lehessen igazítani. A script 16 egymás utáni szegmensfájlt szítál, a szítálás kezdetét 2^{33} -tól 2^{63} -ig változtatja, a kitevőt hármasával növelve, a szegmensek méretét 2^{16} -tól 2^{24} -ig, a kitevőt egyesével növelve, és a számrendszert 2^1 -től 2^8 -ig, szintén a kitevőt egyesével növelve.

3. fejezet

Fejlesztői dokumentáció

3.1. A feladat leírása

A program feladata, hogy lehetővé tegye prímszíták futási idejének összehasonlítását. A prímszíták az egész számok egy intervallumán minden számról eldöntik, hogy a szám prím, vagy összetett. A program keretet ad, hogy azonos paraméterekkel lehessen a szíták futási idejét mérni, és egyszerű, egymáshoz hasonlóan optimalizált szítákat implementál, hogy a futási időket a fő algoritmusok határozzák meg, mivel a szítálást felgyorsító egyes ötletek nem minden szitán alkalmazhatóak. A futási időt eltelt időben, és összeszámolt műveletekben is méri.

A szítákat szegmentáltan valósítja meg, a szegmensek mérete, és a szítálandó intervallum kezdete és vége szabályozható. A megvalósított szíták:

- Atkin szítája
- Eratosthenész szítája
 - egyszerű tömbbel
 - bináris kupaccal
 - edényekkel
 - monoton edénysorral

A programnak grafikusán ábrázolja a futási időket, és lehetőséget ad ezek közelítésére függvényekkel. A közelítéshez a legkisebb négyzetek módszerét használja, és a közelítés elemi függvényei megválaszthatóak. A program megjeleníti a közelítések négyzetes eltérését is a mintához képest. Elemi függvény meg lehet adni JavaScript nyelven is.

A grafikus ábrázolás képes külső forrásokból származó minták megjelenítésére és közelítésére is.

A minták és függvények ábrázolása interaktív, az éppen megjelenített intervallum elhelyezkedése és mérete megválasztható. Egyszerre több mintha is megjeleníthető, és minden mintához egyszerre több közelítő függvény is tartozhat.

A prímszámok statisztikáinak megjelenítéséhez elő tudja állítani ezeket a statisztikákat nagyobb intervallumokon is. Ehhez ad egy szitát, ami hatékonyan képes 2^{64} -ig szitálni, és ennek az eredményét összesíteni. Az előállítható statisztikák adott n -ig szitálva:

- a prímek száma
- a $4\mathbb{Z} + 1, 4\mathbb{Z} + 3, 6\mathbb{Z} + 1, 12\mathbb{Z} + 11$ alakú prímek száma
- ikerprímek számát
- az előforduló prímhézagok első előfordulásának helye
- a prímhézagok előfordulásának száma
- a szitálásra fordított idő

A prímek számát, és a szitálás idejét az intervallum belsejében is több ponton elkészíti.

A sziták sebességének mérését, és a statisztikák előállítását parancssorból is el tudja végezni, hogy szkriptekkel ez automatizálható legyen. A statisztikák előállításának folyamata bármikor adatvesztés leállítható, és később folytatható.

3.2. A program komponensei

Ábra.

```
init -> db -> generátor -> db -> összesítő -> db -> minta megjelenítés -> minta
közelítés -> közelítés megjelenítés
db -> info
db -> sziták -> futási idő minta -> minta megjelenítés -> minta közelítés ->
közelítés megjelenítés
db -> ellenőrzés
db -> sziták -> ellenőrzés
```

A program az adatbáziskönyvtárban tárolja az átszitált szegmensek tábláit, és az ezekből készült statisztikákat. A szegmensfájlokban egy 2^{30} hosszú intervallum minden páratlan számához hozzá van rendelve, hogy az az szám összetett vagy prím, és minden szegmens kezdő száma kongruens $1(mod\ 2^{30})$.

Az első négy szegmenst az init program készíti el, így ezek 2^{32} -ig tartalmazzák a prímszámokat. A program többi szitája ezek alapján inicializálja magát, ha 3-nál

nagyobb számtól kell a szítálást elkezdni. Ez a négy fájl bármikor újragenerálható, de ezeket érdemes a futások között megtartani.

A generátor egy optimalizált szita, 2^{32} -től $2^{64} - 2^{34}$ -ig képes szítálni, mindig egész szegmenseket, és az eredményt az adatbáziskönyvtárba menti. Ezekre a szegmensfájlokra összesítés és ellenőrzés után többet nincs már szükség. A szítálást tetszőleges szegmenstől lehet kezdeni a megengedett tartományon belül, nem szükséges sorban végigmenni a számokon. Az utolsó 2^{34} szám kihagyása egyszerű optimalizáció, így a programban az éppen szitált szám változója sosem csordul túl.

Az init és a generator csak konzol módban futtatható. A program többi része a gui nevű Java program része, de az automatizáláshoz az adatbázissal kapcsolatos műveletei parancssorból is elérhetőek, ezek az adatbázis információ lekérése, az új szegmensfájlok ellenőrzése, és összesítése, és az összesítőfájlok összefésülése. Az időigényessége miatt a futási idő összehasonlításához implementált sziták ellenőrzése is futtatható grafikus felületen, és parancssorból is.

Az adatbázis információ kilistázza a szegmensfájlok számát, az összesített szegmensfájlok számát, ezen szegmensek intervallumának kezdetét és végét, a még nem összesített szegmensfájlok számát. Ezek alapján eldönthető, szítálást vagy az összesítést hogyan kell folytatni, hogy a teljes 2^{64} -ig intervallum statisztikai elkészüljenek.

A szegmensfájlok ellenőrizhetőek, ehhez egy, a generator-tól különböző eratostenészi szita, vagy az erős pszeudo-prímteszt előállítja a szegmens ellenőrzött részét, és a program a kettőt összehasonlítja. A szita lényegesen lassabb, mint a generator, és a pszeudo-prímteszt időigénye miatt intervallumok szítálásra nem alkalmas, a szegmensfájlok ellenőrzése alapvetően a generator helyességének tesztelésére való, minden összesített szegmens ellenőrzése megtöbbszörözné a szükséges időt.

Az összesítő az adatbáziskönyvtárban található szegmensfájlok statisztikáit készíti el, és ezeket a szegmensstatisztikákat szintén az adatbázisban tárolja. A szegmensstatisztikák alapján a végső statisztikákat közvetlenül a megjelenítés előtt készíti el az összesítő. Az összesítéshez sem szükséges, hogy a szegmensek sorban kerüljenek összesítésre, így akár több gépen párhuzamosan is lehetne szítálni, összesíteni, majd az eredményt összefésülni.

A program része több, különböző algoritmusú prímshita. Ezeknek az eredménye ellenőrizhető a szegmensfájlok ellenőrzéséhez használt szitával, szintén a sziták helyességének teszteléséhez. A feladat része, hogy ezeknek a szitáknak a futási idejét össze lehessen hasonlítani, ezért mindegyik szita néhány jól meghatározott ötlet egyszerű megvalósítása optimalizálások nélkül. Mindegyik szita szegmentált, a szítálást fix hosszúságú intervallumokon végzi, bármelyik szegmenstől képes kezdeni a szítálást, és egy szegmens szítálása után további előkészület nélkül képes szítálni a következő szegmenst, így egyetlen menetben akár több szegmenshez tartozó futási idő is megmérhető, nem szükséges minden mintavételi pontig a teljes szítálást

elvégezni.

A minták közelítése alapfüggvények lineáris kombinációjával történik, a legkisebb négyzetek módszerét használva.

A program a mintákat és közelítő függvényeket Descartes-féle koordinátarendszerben jeleníti meg, ehhez a mintákat és a függvényt mintavételezi az x tengely kiválasztott szakaszának pixelenkénti felosztása szerint.

3.3. A forráskód

A megoldás 3 programból áll, az `init` és a `generator` C nyelven készült el, az összes többi részfeladat a `gui` nevű Java nyelven írt programban lett megoldva.

3.3.1. Init és generator

Az `init` és a `generator` forráskódja a `tarball` generator könyvtárában van. A két program egymáshoz nagyon hasonló feladatot lát el, hasonló megoldásokkal. Mindkettő 2^{30} hosszú intervallumokat szítál, és az eredményt szegmensfájlokba írja. Ehhez mindkettő Eratoszthenész szitáját használja. Mindkét program ezt az egyetlen feladatot oldja meg, és szkriptekkel automatizált, köteget futásra van tervezve.

3.3.1.1. Közös rész

A két program közös kódja a `common.h` fájl. Ez a fájl tartalmazza a konstansokat, és az eljárásokat, amik megkönnyítik a POSIX hívások használatát. A legtöbb ilyen könnyítés a hibák kezelésének elfedése, ami a köteget futtatáshoz illeszkedően a hiba kijelzése utáni azonnali programleállítás. Az I/O műveleteket könnyítik meg a `readFully/writeFully` eljárások.

A sziták belső, kis szegmensmérete a `SEGMENT_SMALL_SIZE_BITS_LOG2` konstanssal szabályozható, és a `measure-generator` script kimenete alapján egy adott géphez igazítható.

Ez a közös header fájl határozza meg a szegmensfájlok formátumát, a `readSegment/writeSegment` eljárásokkal. A fájl neve a `"primes."` előtaggal kell kezdődjön, és a pontosan 16 hexadecimális számjegy kell kövesse, a szegmens által leírt első szám. A fájl egyszerű bináris fájl, kis endian sorrendben. A tartalma:

- a szegmens elejével kezdve 2^{29} egymást követő páratlan szám bittérképe.

Ez 2^{26} byte, kis endian sorrendben minden bit egy szám összetettségét írja le. Ha a bit 1, akkor a szám összetett, ha 0, akkor a szám prím. Ha s a szegmens intervallumának kezdete, akkor az 0. bájt 0. bitje s -t írja le, a 0. bájt 1. bitje $s + 2$ -t, a k . bájt l . bitje $s + 16k + 2l$ -t.

- a szegmens kezdete, 8 bájt
- a szegmens szítálására való felkészülés ideje, 8 bájt, nanoszekundumokban
- a szegmens szítálásának ideje, 8 bájt, nanoszekundumokban

A `writeSegment` meghatározza a szegmensfájlok írásának menetét is. Ahhoz, hogy a program bármikor leállítható legyen, a szegmensfájl kiírása először egy ideiglenes fájlba történik, és ha ez hiba nélkül megtörtént, akkor a az ideiglenes fájl átnevezi a megfelelő névre. Mivel az ideiglenes fájl ugyanabba a könyvtárba kerül, mint ahova a szegmensfájl is, így feltételezhető, hogy helyi meghajtón az átnevezés már atomi művelet.

Ez az eljárás az átnevezés előtt nem győződik meg arról, hogy az ideiglenes fájl minden része kiíródott a háttértárra, így ez csak a program leállíthatóságát garantálja, a számítógép váratlan leállása esetén érdemes azokat a szegmensfájlokat letörölni, amikről feltételezhető, hogy nem volt ideje a számítógépnek minden részét kiírnia a tényleges tárolóra.

3.3.1.2. Init

Az `init` program előállítja az első 4 szegmens fájl, azaz 2^{32} -ig az összes prímet megkeresi. Ezzel a többi részprogram már a $2^{32} - 2^{64}$ tartomány tetszőleges részén tud szítálni, anélkül, hogy a szítált szegmenseket a szítálás után végig kéne nézze új prímekért.

A szita egy egyszerű szegmentált eratoszthenészi szita. A 2^{30} hosszú szegmenseket több kisebb, egyenlő szegmensre osztja, és ezeket a kis szegmenseket egymás után szítálja a prímek listáján végigmenve. A prímek mellett a következő szítálás helyét is eltárolja, így nem kell minden szegmens szítálásának elején minden prímmel osztással meghatározni, hogy melyik a legkisebb szám a szegmensben, amit az oszt. Így egy kis szegmensben egy prímmel a következő algoritmus fut le. Ez az algoritmus visszatérő minta a szegmentált szitákban.

```

1: p: a prím
2: q: a következő szám, amit p oszt
3: e: a szegmens vége
4: while q < e do
5:   MEGJELÖL(q)
6:   q = q + 2p
7: end while
```

A prímek listáját elég 2^{16} -ig előállítani, ezt a program próbaosztással végzi el.

3.3.1.3. Generator

A generator fő részei hasonlóak az init-hez. Indulása után felolvassa az összes prímet az első 4 szegmensfájlból, és mindegyik prímhez osztással meghatározza, hogy melyik a legkisebb szám, amit oszt, és legalább akkora, mint legelső szítálandó szegmens kezdete. A prímek, és a hozzájuk tartozó következő szítálandó pozíciót tároló adatstruktúra szítálás közben nem érzékeny azokra az elemekre, amik az éppen szítált szegmensnél nagyobb helyeken szítálnak, így a generator az összes prímet eltárolja 2^{32} -ig, nem csak a szítálandó tartomány végének négyzetgyökéig, és a prímek első többszörösét is a prím négyzetétől szítálja.

A prímek listájának inicializálása után a nagy szegmenseket az inithez hasonlóan kisebbekre osztja, és ezeket sorban szítálja a prímek listája alapján.

A prímek listája a generatorban több külön adatszerkezet összessége. A prímeket a szita inicializálásánál 3 részre osztja a nagyságuk szerint. A 64-nél kisebb prímeket 64-bit széles bitmintákban tárolja, és ezekkel a mintákkal 64-bitesével szítálja végig a kisszegmenseket a bitenkénti vagy művelettel. A 3 és a 11, valamint az 5 és a 7 szorzata kisebb, mint 64, ezeket a párokat egyetlen 64 bites mintába fejt ki, ezeknek a mintáknak a periódusa 33, és 35. A többi prím mintájának periódusa a legnagyobb olyan szám, ami 64-nél kisebb, és a prím osztja.

A prímek, amik 64-nél nagyobbak, de a kis szegmensek hosszánál kisebbek, azaz minden kis szegmensben szítálnak, az init-hez hasonlóan egy egyszerű tömbbe kerülnek, és ugyanúgy szítál ezekkel a program, mint az init-ben.

A kis szegmensek hosszánál nagyobb prímek egy kis szegmensben legfeljebb egyszer szítálnak, és van olyan szegmens, ahol egyszer sem. A generator ezeket a prímeket egy prioritásos sorban tárolja, amiben az elemek sorrendjét a következő szegmens száma határozza meg, amiben az a prím szítálni fog, a szegmensben belüli sorrendet a sor nem veszi figyelembe. Ezeknél a nagy prímeknél nem csak a páros többszörösöket ugorja át a szita, hanem a 3-mal és 5-tel osztható többszörösöket is kihagyja.

mi a kerék magyarul?

Az edénysor algoritmusának részletes leírására egy későbbi fejezetben kerül sor. Az ott leírt távolság függvényt implementálja a bucketIndex függvény a forráskódban. A számrendszert a BUCKET_BITS konstans szabályozza. A sorhoz tartozó edények listája a buckets tömb, ennek minden eleme egy láncolt lista, ahol a listaelemek fix méretű edények.

A program futása alatt a sor elemeinek száma nem változik, de az elemek az edények között mozognak. A sor legkisebb elemeinek, azaz az aktuális szegmensben szítáló prímek megkereséséhez a lista egyik edényének minden elemét megvizsgálja, ha egy elem az aktuális szegmensben nem szítál, akkor az elemet a sorba visszahelyezi, a távolság függvény szerint már közelebbi edénybe, ha pedig az elem szítál

az aktuális szegmensben, akkor elvégzi a szitálást, és az elemet visszateszi a sorba, azon pozíció szerint, ahol a prím legközelebb szitálni fog.

A 2, 3, és 5 többszöröseinek hatékony kihagyásához a prioritásos sor elemeiben a pozíció mellett el van tárolva, hogy az a pozíció melyik modulo 30 maradékosztály eleme. A nyolc szóba jöhető lehetőség közül a `PrimePosition.prime` mező felső 3 bitje választ. Ezt a 3 bit információt biztonsággal lehet itt tárolni, a 64 bit széles változóból a feladat határai miatt mindig csak az alsó 32 tartalmaz értékes számjegyet. A **2-3-5 kerék** alapú gyorsítás csak a prioritásos sorban tárolt nagy prímekre van alkalmazva.

3.3.2. Gui

class diagram. rizsa. lib. commands. gui. max 4gb, autoboxing, mi az, miért nem jó. allokáció/deallokáció elkerülése, from-to ahogy c/java-ban

3.3.2.1. gui.util

A csomag néhány közismert algoritmust és adatszerkezetet tartalmaz, valamint az ezekhez szükséges funkcionális interfészek definícióit. A legtöbbnek létezik sztenderd könyvtári megvalósítása, de ezek referencia típusokat használnak.

A `PrimitiveList` és leszármazottai az `ArrayList` mintájára szükség szerint növekvő vektorok. Konkrét megvalósítások a `double`, `int`, és `long` primitív típusokra vannak.

A `BinarySearch` és a `QuickSort` a bináris keresés és a quicksort algoritmusát valósítják meg absztrakt módon, az elemeket közvetlenül sosem érik el, az összehasonlításokat és a cseréket interfészeken keresztül végzik index alapján.

A `BinaryMinHeap` egy bináris kupac, mint absztrakt konténerosztály, az elemek típusától függő műveleteket absztrakt metódusként határozza meg. A kupac egy elsőbbségi sor, a sor eleje az absztrakt rendezés legkisebb eleme.

3.3.2.2. gui.math

Ebben a csomagban az osztályok két részre oszthatóak. Az `UnsignedLong` a Java `long` típus előjel nélküli műveleteit valósítja meg. A Java a 8-as verziótól támogatja a primitív egész típusok előjel nélküli összehasonlítását és osztását, ez az osztály ezekre építve ad néhány segédeljárást. A pszeudoprím-teszthez a maradékos hatványozás Java támogatás nélkül a kitevő bitjei alapján ismételt szorzást és négyzetre emelést használja, míg a szorzás ehhez hasonlóan összeadást és kétszerezést. Ezeknek az algoritmusoknak a futási ideje egy-egy szám esetén elfogadhatóak, de intervallumok szitálására nem alkalmasak.

A csomag többi osztálya a legkisebb négyzetek módszerének implementációja, és annak segédosztályai.

A Sum double típusú értékek véges összegeit számolja ki. A double véges pontosságú reprezentációjának következménye, hogy többtagú összeg eredménye függhet a tagok összeadásának sorrendjétől, azaz hiba keletkezhet. A Sum három stratégiát ad ennek minimalizálására. A program használata közben a felhasználó ezek közül nem tud választani, **a tesztek alapján legstabilabbnak ítélt elsőbbségi soron alapuló** összegzést használja a közelítés. A legegyszerűbb Sum.Simple a tagokat felsorolásuk sorrendjében adja össze. A bináris kupacot használó Sum.Priority a tagokat a sorban gyűjti, majd az összeadásra, amíg lehet, a két legkisebb abszolút értékű elemet választja ki, majd az eredményt a sorba visszahelyezi. A Sum.Array nagyságrend szerinti részösszegeket tart nyilván, új tagot a nagyságrendjéhez tartozó részösszeghez adja hozzá. A nagyságrend a double érték IEEE 754 szabvány szerinti reprezentáció kitevője.

A RealFunction interfész valóshoz valós függvények reprezentációi, közelítés elemi függvényei. Egy függvény a helyettesítési értékén kívül az értelmezési tartományát is meg kell adja, igaz értéket akkor kell adjon a kért intervallumra, ha annak minden pontjában értelmezve van. A függvény grafikonján csak az ilyen az teljesen értelmezett egy pixel széles oszlopokon fog függvényértéket megjeleníteni. A Functions osztály a beépített elemi függvényeket tartalmazza. JavaScript-ben függvény a CustomFunction-nel adható meg. A legkisebb négyzetek módszerével kapott függvényt a LinearCombinationFunction írja le, ebből a lineáris kombináció skaláris értékei is kiolvashatóak.

A Matrix osztályban vannak megadva a valós mátrixok műveletei, mindegyik kétdimenziós double tömbökre. Az implementált műveletek a legkisebb négyzetek módszeréhez szükségesekre korlátozódnak. A Gauss-eliminációnál kiválasztható, hogy részleges sorcserére, vagy teljes sor és oszlopcserére kerüljön sor. **A tesztek alapján a teljes csere egyértelműen csökkenti a számítás hibáját, a felhasználó részleges sorcserét nem is tud választani.**

A LeastSquares osztályban lett megvalósítva a legkisebb négyzetek módszere. A csomag eddig felsorolt osztályaival itt lehet megadni a közelítéshez, a mintán kívül, az elemi függvényeket, és a pontosságot szabályozó paramétereket. A közelítés hibáját is ki lehet ezzel az osztállyal számolni.

3.3.2.3. gui.io

3.3.2.4. gui.ui

3.3.2.5. gui.sieve

3.3.2.6. Adatbázis műveletek

3.3.2.7. Grafikus megjelenítés

3.4. Adatszerkezetek

3.5. Numerikus algoritmusok

Egyenletrendszerek. Összeadás. Körül kéne írni, hogy igazán tudjuk, hogy hipotézisvizsgálatra nem vállalkozunk. A grafikonrajzolónak sokkal okosabbnak kéne lennie, hogy gyorsan változó függvényeket helyesen jelenítsen meg, reménytelenül okosnak.

3.6. Sziták

Eratosztenész szitája, szegmentáltan is. COLS. Prioritásos sorral. Atkin szitája.

Szegmentált szita inicializálása.

Trial division. Pszeudoprím teszt.

Feltételek. Elméleti sebesség.

3.7. Prioritásos sorok

```
1:  $q \leftarrow \text{ÚJ-SOR}$ 
2: for  $i \leftarrow 2, n$  do
3:   while  $\exists (p, k) \in q : k \leq i$  do
4:      $(p, k) \leftarrow \text{SOR-ELTÁVOLÍT-MIN}(q)$ 
5:      $\text{MEGJELÖL}(i)$ 
6:      $\text{SOR-BESZÚR}(q, (p, k+p))$ 
7:   end while
8:   if  $\neg \text{MEGJELÖLT?}(i)$  then
9:      $\text{SOR-BESZÚR}(q, (i, 2i))$ 
10:  end if
11: end for
```

3.7.1. Bináris kupac

A mérések grafikonják pixelei alapján lassú. A beszúrásonkénti elméleti $\mathcal{O}(\log|q|)$ ideje se biztató.

3.7.2. Bigyó

A bigyó egy monoton prioritásos sor. A sor monoton, minden állapothoz tartozik egy érték, a sor aktuális pozíciója, aminél kisebb vagy egyenlő pozíciójú értéket a sor nem tartalmazhat. A bigyó edények egy végtelen sorozatát is tárolja, a sor elemei ezekbe az edényekbe kerülnek. Egy eltárolt elem helyét a sorozatban az elem pozíciójának és a sor aktuális pozíciójának távolsága határozza meg.

A távolságfüggvény legyen

$$d(x, y) := \lfloor \log_2(x \oplus y) \rfloor \quad (x, y \in \mathbb{N}, y > x \geq 0)$$

ahol \oplus a bitenkénti XOR.

$d(x, y)$ a legnagyobb bit-index, ahol x és y eltér.

Ha q egy bigyó, legyen $q.a$ q aktuális pozíciója, és $q.e[i]$ q i . edénye. AZ edények, és a számpárok struktúrája...

Egy q bigyó invariánsa

$$\forall (p, k) \in q :$$

$$q.a < k$$

$$\forall i \in \mathbb{N}_0 : (p, k) \in q.e[i] \iff i = d(q.a, k)$$

$$\forall (p, k) \notin q : \forall i \in \mathbb{N}_0 : (p, k) \notin q.e[i]$$

Új, üres sor létrehozása tetszőleges kezdőpozíciótól, és meglévő sorba elem beszúrása...

A sor elemeinek feldolgozása i -ig

```
1: while  $q.a < i$  do
2:    $j \leftarrow d(q.a, q.a + 1)$ 
3:    $q.a \leftarrow q.a + 1$ 
4:   for all  $(p, k) \in q.e[j]$  do
5:     EDÉNY-KIVESZ( $q.e[j], (p, k)$ )
6:     if  $k = i$  then
7:       VISSZAAD( $(p, k)$ )
8:     else
9:       EDÉNY-BESZÚR( $d(q.a, k), (p, k)$ )
```

```
10:         end if
11:     end for
12: end while
```

3.7.2.1. Helyesség

3.7.2.2. Idő

3.7.2.3. Hely

3.7.2.4. Számrendszer

És számrendszer vs. tisztán funkcionálisban nincs bármekkora tömb, csak valami fával közelítve.

Amúgy sincs bármekkora tömb...

És exponenciálisan kell növelni...

3.7.2.5. Cache

És exponenciálisan kell növelni...

3.8. Memória

Összes prím, és pozíciója 2^{32} -ig. Primitív típusok és boxing. Garbage collector.

3.9. Teszt

3.9.1. Adatszerkezetek

3.9.2. Numerikus pontosság és sebesség

3.9.3. Sziták

3.9.4. Elmélet vs. mért

4. fejezet

Irodalomjegyzék

- [1] A. O. L. Atkin, D. J. Bernstein: Prime sieves using binary quadratic forms, Mathematics of Computation, Volume 73 (2004) 1023–1030
- [2] A. Járαι, E. Vatai: Cache optimized linear sieve, Acta Univ. Sapientiae, Inform. 3,2 (2011) 205-223