



Eötvös Loránd Tudományegyetem

Informatikai Kar

Komputeralgebra Tanszék

---

# Prímszita algoritmusok összehasonlítása

Vatai Emil  
Adjunktus

Nagy Péter  
Programtervező Informatikus BSc

Budapest, 2018

# Tartalomjegyzék

<b>1. Bevezetés</b>	<b>2</b>
<b>2. Felhasználói dokumentáció</b>	<b>3</b>
2.1. A megoldott feladat . . . . .	3
2.2. Felhasznált módszerek . . . . .	3
2.3. A program telepítése és futtatása . . . . .	4
2.4. Prímek keresése . . . . .	5
2.5. Mintaadatbázis karbantartása . . . . .	6
2.6. Szitatóablák ellenőrzése . . . . .	8
2.7. Minta megjelenítése . . . . .	8
2.8. Minta közelítése függvényekkel . . . . .	8
2.9. Minták generálása scriptekkel . . . . .	8
2.10. Sziták ellenőrzése scriptekkel . . . . .	8
<b>3. Fejlesztői dokumentáció</b>	<b>9</b>
3.1. A feladat leírása . . . . .	9
3.2. A program komponensei . . . . .	9
3.3. A forráskód felosztása . . . . .	9
3.4. Adatszerkezetek . . . . .	9
3.5. Numerikus algoritmusok . . . . .	9
3.6. Sziták . . . . .	9
3.7. Prioritásos sorok . . . . .	9
3.7.1. Bináris kupac . . . . .	10
3.7.2. Bigyó . . . . .	10
3.8. Memória . . . . .	11
3.9. Teszt . . . . .	11
3.9.1. Adatszerkezetek . . . . .	11
3.9.2. Numerikus pontosság és sebesség . . . . .	11
3.9.3. Sziták . . . . .	11
3.9.4. Elmélet vs. mért . . . . .	11
3.10. Források . . . . .	11

# 1. fejezet

## Bevezetés

Sziták összehasonlítása azonos környezetben. Hatékonyság összehasonlítása az elmélet szerint várható értékekkel. Ellenőrzésként a prímek néhány statisztikájának összevetése az elméleti értékekkel, és az ismert eredményekkel. Hatékonyság és implementálhatóság.

## 2. fejezet

# Felhasználói dokumentáció

### A megoldott feladat

A program lehetővé teszi különböző sziták futási idejének ábrázolását grafikonon, és összevetését elméleti becsült értékekkel. A programmal egyéb forrásból származó minták megjelenítése is lehetséges.

A prímszámok statisztikáinak előállításához a programhoz tartozik egy optimalizált szita-implementáció, amivel  $2^{64}$ -ig lehet szitálni, és az eredményt rögzíteni. Az elmentett eredményeket a program egy külön része összesíti néhány alapstatisztikákra.

Különböző szita-algoritmusok futási idejének összehasonlításához a program tartalmazza Atkin szitájának egy implementációját, és Eratoszthenész szitájának néhány variációját.

### Felhasznált módszerek

A program két rész fő részből áll. A prímszámok generátora C-99 nyelven készült el. A program csak parancssorból futtatható, és a sztenderd könyvtári függvényekből is csak néhányat használ a memóriájában előállított eredmények fájlba írásához. A C nyelv választását a hatékony végrehajtás és memórafelhasználás, és a hordozhatóság indokolja, a generátor elkülönítését az automatizálhatóság indokolja.

A prímgenerátor Eratoszthenész szitájának szegmentált változata, a szitatábla egy  $2^{30}$  hosszú darabját szitálja ki minden iterációban. A generátor önmaga is két részből áll. Egy egyszerűbb implementáció a prímek listáját állítja elő  $2^{32}$ -ig.

A gyorsabb, de összetettebb szita  $2^{32}$ -tól  $2^{64} - 2^{34}$ -ig szital, és a futásához szükséges a prímek listája  $2^{32}$ -ig. A szitatáblát a memóriában a gyorsítótár hatékonyabb a kihasználásához kisebb részegemensekre osztja, és a prímeket a nagyságuk és a következő szitalási pozíciójuk szerint csoportosítja. Továbbá nagyobb prímeknek

csak harminccal relatív prím többszöröseit veszi figyelembe.

A program többi része a Java környezethez készült, a képzésben betöltött szerepe és a hordozhatósága miatt. A minták és függvények ábrázolásához használt Swing grafikus könyvtár a Java környezet része, egyszerű, hordozható, támogatja az élsimítást, és a sebessége elfogadható a feladatra. A Java sztenderd konténerosztályai habár kényelmesen használhatóak, és változatosak, de sebesség és memóriakihasználtsági problémák miatt több helyen is alacsonyabb szintű megoldást kellett választani.

A program a mintákat alapfüggvények lineáris kombinációjával képes közelíteni, a legkisebb négyzetek módszerével. A minták elemeinek nagy száma, és a mintaértékek nagy terjedelme miatt szükséges volt a numerikus algoritmusok nagyobb pontosságú implementációja, ami a számítási idő növekedésével jár.

A program hosszabb távon egyedül a prímek szegmensenkénti statisztikáit tárolja, amit csak sorban dolgoz fel, és a statisztikák összmérete sem indokolna egy egyszerű bináris fájlnál bonyolultabb megoldást. Az adatvesztés elkerüléséhez elég a statisztikafájl csere alapú felülírása.

A Java program tartalmaz több prímszita implementációt is, ezeknek az algoritmikus bonyolultsága különböző, de az összehasonlíthatóságához a közös részek közös implementációt kaptak, és az eltérő részek hasonló szinten optimalizáltak. A sziták helyességének ellenőrzéséhez a sziták eredménye egymással összehasonlítható. A programhoz elkészült Atkin szitája, és Eratoszthenész szitájának több variációja: az algoritmus legegyszerűbb implementációja a teljes szitatáblán jelöli meg a prímek többszöröseit, a többi a táblát rövidebb szegmensekre osztja fel, és ezeket sorban szitálja. A szegmentálás szükségessé teszi, hogy eldöntsük, hogy mely szegmensben mely prímek szitálnak. A legegyszerűbb megvalósítás minden szegmensben minden prímmel megpróbál szitálni, a próbaosztáshoz hasonlóan. Ennél hatékonyabb a két elsőbbségi sorral megvalósított szita, és a harmadik, edényekbe csoportosító megoldás.

A sziták között kapott helyet a próbaosztás, és az erős pszeudo-prím teszt is, de ezek a lassúságuk miatt csak igen rövid tartományok ellenőrzésére alkalmasak.

## A program telepítése és futtatása

A Java program futtatásához JRE8-ra van szükség, a fordításához JDK8-ra. A C program fordításához C99 szabványú fordítóprogram kell. A program fejlesztése és tesztelése OpenJDK8-cal és GCC 7.3-mal történt Linux operációs rendszeren.

A tarball a Java programot lefordítva is tartalmazza, kicsomagolás után azonnal futtatható. A C programot a generator könyvtárban található Makefile segítségével lehet lefordítani:

```
generator$ make clean build
```

A Java program a NetBeans 8-as verziójával készült, parancssorból a project ant fájljának segítségével lehet újrafordítani:

```
gui$ ant clean jar
```

A program futtatásához több előkészített script is rendelkezésre áll, ezeket mind a scripts könyvtárból lehet indítani. Az előző két fordítást egyben is el lehet végezni a recompile scripttel:

```
scripts$ ./recompile
```

## Prímek keresése

A prímek keresését két program végzi, az init program  $2^{32}$ -ig keresi meg és tárolja el a prímeket, a generator  $2^{32}$ -tól  $2^{64} - 2^{43}$ -ig. Az init készítette szitattáblák a generator futásához szükségesek.

Mindkét program a számokat  $2^{30}$  hosszú táblánkként szitálja, minden tábla első száma  $2^{30}k + 1$  alakú. A szitattáblákat a programok a fájlrendszerben bittérképként tárolják, egy tábla kb. 64Mb.

Az első négymilliárd szám szitálása a következő képpen indítható el:

```
generator$ ./init.bin ../db
segment 0 - start          1 - init 152 512 370 ns - sieve 1 068 908 595 ns
segment 1 - start 1 073 741 825 - init  2 095 563 ns - sieve 1 117 359 702 ns
segment 2 - start 2 147 483 649 - init  2 107 942 ns - sieve 1 127 848 722 ns
segment 3 - start 3 221 225 473 - init  1 996 728 ns - sieve 1 145 187 514 ns
```

Ennek eredmény 4 bittérkép-fájl, amit a db mappába ment.

A generator programot több féle képpen is lehet indítani. Mindegyik esetben két paramétert kell megadni az indításhoz, a számot, ahol szitálást kezdje, és a szegmensek számát, amit ebben a futásban végig kell szitálni. A kezdő számot meg lehet adni decimálisan is, vagy hexadecimálisan is, "0x" prefixszel. A szegmensek számát is kétféle képpen lehet szabályozni. Az egyik lehetőség fix számú szegmens megadása, decimálisan. A másik mód a háttértáron fenntartandó szabad hely átadása, decimálisan, vagy "0x" prefixszel hexadecimálisan.

```
generator$ ./generator.bin ../db start 0x100000001 segments 3
segment start: 4 294 967 297
segment count: 3
small segment size: 22
bucket bits: 8
init segment 0
init segment 1
init segment 2
init segment 3
init end
segment 4 - start 4 294 967 297 - init 7 812 301 909 ns - sieve 704 592 094 ns
segment 5 - start 5 368 709 121 - init          340 ns - sieve 707 145 420 ns
segment 6 - start 6 442 450 945 - init          371 ns - sieve 715 291 366 ns
all sieve nanos 2 127 028 880 ns
```

```
generator$ ./generator.bin ../db start 0x100000001 reserve-space 1000000000
segment start: 4 294 967 297
space to reserve: 1 000 000 000
small segment size: 22
bucket bits: 8
```

```

init segment 0
init segment 1
init segment 2
init segment 3
init end
segment 4 - start 4 294 967 297 - init 7 834 902 368 ns - sieve 693 775 928 ns
segment 5 - start 5 368 709 121 - init 1 018 ns - sieve 705 013 333 ns
segment 6 - start 6 442 450 945 - init 16 917 ns - sieve 705 195 144 ns

```

Mindkét program kimenetében a start a szegmens kezdőszáma, a segment az indexe,  $start = segment \cdot 2^{30} + 1$ , az init a szita inicializálási ideje a szítálás előtt, és a sieve a szegmens szítálásának ideje. Ezek az információk az elmentett táblafájlokból is kiolvashatóak.

## Mintaadatbázis karbantartása

A mintaadatbázis a lementett szitatáblák összesített statisztikáit tárolja. A program az adatbázis könyvtárában kétfajta fájlt vesz figyelembe. A "primes\[0-9a-f]{16}" reguláris kifejezésnek megfelelő nevű fájlok a szegmensok szitatáblái. A fájlnev második fele a szegmens kezdőszáma hexadecimálisan. A fájl a páratlan számok bittérképe mellett tartalmazza a szegmens szítálásának megkezdésére, és a szítálására fordított időt, valamint ellenőrzésképpen a szegmens kezdőszámát is.

A szitatáblák mellett az adatbázis tartalmazhatja szegmensok összesített statisztikáit is, "aggregates" néven. Ez a fájl az eddig összesített szegmensről a következő információkat tartja nyilván:

- a szegmens kezdőszáma
- a szegmens szítálására való felkészülés idejét
- a szegmens szítálásának idejét
- az összesítésre fordított időt
- a szegmensfájl utolsó módosítási idejét
- a szegmensbe eső legkisebb, és legnagyobb prímet
- a szegmensbe eső prímek számát,  $12\mathbb{Z}11$ ,  $4\mathbb{Z}1$ ,  $4\mathbb{Z}3$ ,  $6\mathbb{Z}1$  alakok szerinti bontásban
- a szegmensben előforduló prímhézagok első előfordulásának helyét, és az előfordulások számát.

Az adatbázison három művelet végezhető:

- Le lehet kérni, hogy eddig hány szegmens van összesítve, és melyik a következő hiányzó szegmens. Azt is visszaadja, hogy hány szegmensfájl van épp az adatbázis könyvtárában, és hogy ezek között van-e olyan, ami nincs összesítve.
- Összesíteni lehet az új szegmensfájlok.
- Össze lehet fésülni két összesítőfájlt.

Mindhárom művelet elvégezhető grafikus felületen, és automatizáláshoz parancssorból is. A grafikus felületet a gui scripttel lehet indítani, a parancssorból a database script segítségével lehet elérni a műveleteket.

Ezek a scriptek határozzák meg, hogy a program melyik könyvtárat használja adatbázisként, ezt nem kell külön megadni. Szükség esetén ez a könyvtár a scriptek egyszerű módosításával megváltoztatható.

A szegmensinformációkat a grafikus felületen a "DB info" gomb megnyomásával lehet lekérdezni, parancssorból a "database info" kiadásával.

```
scripts$ ./database info
100%
segment files: number of segments: 4
segment files: start of the first segment: 1
segment files: start of the last segment: 3,221,225,473
segment files: start of the first missing segment: 4,294,967,297
segment files: number of missing segments: 18,446,744,073,709,551,596
aggregates: number of segments: 4
aggregates: start of the first segment: 1
aggregates: start of the last segment: 3,221,225,473
aggregates: start of the first missing segment: 4,294,967,297
aggregates: number of missing segments: 18,446,744,073,709,551,596
new segment files: 4

scripts$ ./database info crunch 100
100%
segment files: number of segments: 4
segment files: start of the first segment: 1
segment files: start of the last segment: 3,221,225,473
segment files: start of the first missing segment: 4,294,967,297
segment files: number of missing segments: 18,446,744,073,709,551,596
aggregates: number of segments: 4
aggregates: start of the first segment: 1
aggregates: start of the last segment: 3,221,225,473
aggregates: start of the first missing segment: 4,294,967,297
aggregates: number of missing segments: 18,446,744,073,709,551,596
crunch: ../generator/generator.bin ../db start 0x100000001 segments 0x64
```

A "crunch" utótag és szitálni kívánt szegmensek számának megadásával az utolsó sorban a következő futtatásra ajánlott parancsot is megjeleníti a program. Ezeknek a parancsoknak a követésével a teljes szitálható tartományt fel lehetne dolgozni. A "crunch-numbers" script ezt a feladatot kíséri meg elvégezni.

Az info megjeleníti az új szegmensfájlok számát is, azokat, amikhez vagy nem tartozik összesített adat, vagy tartozik, de az ott tárolt utolsó módosításnál újabb a szegmensfájl. Ezeket a "DB reaggregate" gomb megnyomásával, vagy a "database reaggregate" paranccsal lehet összesíteni.

```
scripts$ ./database reaggregate
100%
```

Lehetőség van egy másik adatbázisból statisztikák átvételére is. Az összefésülést a grafikus felületen a "DB import" megnyomása után egy file kiválasztásával lehet indítani, parancssorból a "database import aggregates fájlnev" kiadásával. A megadott fájlból azokat a szegmeneseket veszi át a program, amik vagy nincsenek még meg az adatbázisban, vagy megvannak, de az importált statisztikák utolsó módosítási ideje nagyobb az adatbázisban lévőnél.

```
scripts$ ./database import aggregates ../db/aggregates.large
100%
```



Szitatáblák ellenőrzése

Minta megjelenítése

Minta közelítése függvényekkel

Minták generálása scriptekkel

Sziták ellenőrzése scriptekkel

## 3. fejezet

# Fejlesztői dokumentáció

A feladat leírása

A program komponensei

A forráskód felosztása

Adatszerkezetek

Numerikus algoritmusok

Egyenletrendszerek. Összeadás. Körül kéne írni, hogy igazán tudjuk, hogy hipotézisvizsgálatra nem vállalkozunk.

Sziták

Eratoszthenész szitája, szegmentáltan is. COLS. Prioritásos sorral. Atkin szitája.

Szegmentált szita inicializálása.

Trial division. Pszeudoprím teszt.

Feltételek. Elméleti sebesség.

Prioritásos sorok

```
1:  $q \leftarrow \text{ÚJ-SOR}$ 
2: for  $i \leftarrow 2, n$  do
3:   while  $\exists(p, k) \in q : k \leq i$  do
4:      $(p, k) \leftarrow \text{SOR-ELTÁVOLÍT-MIN}(q)$ 
5:      $\text{MEGJELÖL}(i)$ 
```

```

6:      SOR-BESZÚR( $q$ , ( $p$ ,  $k+p$ ))
7:  end while
8:  if  $\neg$  MEGJELÖLT?( $i$ ) then
9:      SOR-BESZÚR( $q$ , ( $i$ ,  $2i$ ))
10:  end if
11: end for

```

## Bináris kupac

A mérések grafikonják pixelei alapján lassú. A beszúrásonkénti elméleti  $\mathcal{O}(\log|q|)$  ideje se biztató.

## Bigyó

A bigyó egy monoton prioritásos sor. A sor monoton, minden állapotához tartozik egy érték, a sor aktuális pozíciója, aminél kisebb vagy egyenlő pozíciójú értéket a sor nem tartalmazhat. A bigyó edények egy végtelen sorozatát is tárolja, a sor elemei ezekbe az edényekbe kerülnek. Egy eltárolt elem helyét a sorozatban az elem pozíciójának és a sor aktuális pozíciójának távolsága határozza meg.

A távolságfüggvény legyen

$$d(x, y) := \lfloor \log_2(x \oplus y) \rfloor \quad (x, y \in \mathbb{N}, y > x \geq 0)$$

ahol  $\oplus$  a bitenkénti XOR.

$d(x, y)$  a legnagyobb bit-index, ahol  $x$  és  $y$  eltér.

Ha  $q$  egy bigyó, legyen  $q.a$   $q$  aktuális pozíciója, és  $q.e[i]$   $q$   $i$ . edénye. AZ edények, és a számpárok struktúrája...

Egy  $q$  bigyó invariánsa

$$\begin{aligned}
& \forall (p, k) \in q : \\
& \quad q.a < k \\
& \quad \forall i \in \mathbb{N}_0 : (p, k) \in q.e[i] \iff i = d(q.a, k) \\
& \quad \forall (p, k) \notin q : \forall i \in \mathbb{N}_0 : (p, k) \notin q.e[i]
\end{aligned}$$

Új, üres sor létrehozása tetszőleges kezdőpozíciótól, és meglévő sorba elem beszúrása...

A sor elemeinek feldolgozása  $i$ -ig

```

1: while  $q.a < i$  do
2:    $j \leftarrow d(q.a, q.a + 1)$ 
3:    $q.a \leftarrow q.a + 1$ 
4:   for all  $(p, k) \in q.e[j]$  do
5:     EDÉNY-KIVESZ( $q.e[j]$ , ( $p, k$ ))

```

```

6:      if  $k = i$  then
7:          VISSZAAD( $(p, k)$ )
8:      else
9:          EDÉNY-BESZÚR( $d(q.a, k), (p, k)$ )
10:     end if
11: end for
12: end while

```

**Helyesség**

**Idő**

**Hely**

**Számrendszer**

És számrendszer vs. tisztán funkcionálisban nincs bármekkora tömb, csak valami fával közelítve.

Amúgy sincs bármekkora tömb...

És exponenciálisan kell növelni...

**Cache**

És exponenciálisan kell növelni...

**Memória**

Összes prím, és pozíciója  $2^{32}$ -ig. Primitív típusok és boxing. Garbage collector.

**Teszt**

**Adatszerkezetek**

**Numerikus pontosság és sebesség**

**Sziták**

**Elmélet vs. mért**

**Források**