

Eötvös Loránd Tudományegyetem

Informatikai Kar

Komputeralgebra Tanszék

Prímszita algoritmusok összehasonlítása

Vatai Emil Adjunktus Nagy Péter

Programtervező Informatikus BSc

Tartalomjegyzék

1.	Bevezetés						
2.	Felh	Felhasználói dokumentáció					
	2.1.	A meg	goldott feladat	4			
	2.2.	A szof	tver komponensei	4			
		2.2.1.	Init és generator program	6			
		2.2.2.	Gui	6			
	2.3.	A prog	gram telepítése és futtatása	7			
	2.4.	Prímel	k keresése	8			
	2.5.	Az ada	atbázis karbantartása	9			
		2.5.1.	Adatbázis műveletei	11			
		2.5.2.	Adatbázis információk	11			
		2.5.3.	Szegmensek összesítése	12			
		2.5.4.	Összesítőfájlok összefésülése	13			
	2.6.	Az in:	it és a generator eredményeinek ellenőrzése	13			
	2.7.	A gui	szitáinak ellenőrzése	14			
	2.8.	Minta	megjelenítése	15			
		2.8.1.	Minta hozzáadása	15			
		2.8.2.	Minta közelítése	17			
		2.8.3.	Sziták futási idejének mérése szkriptekkel	18			
	2.9.	A gene	erator futási idejének mérése	19			
3.	Feil	esztői	dokumentáció	21			
	3.1.		atbázis	21			
	3.2.						
	J	3.2.1.	Közös rész	24			
		3.2.2.	Init	24			
		3.2.3.	Generator	25			
	3.3.						
	J.J.	3.3.1.	gui.util				
		J.J. I.	0				

4.	Irod	alomje	egyzék	50
		3.5.1.	Legkisebb négyzetek módszere	47
	3.5.		ram ellenőrzése	
		3.4.2.	Edénysor	40
		3.4.1.	Prioritásos sorok	39
	3.4.	Sziták		38
		3.3.10.	Grafikon ábrázolása	35
		3.3.9.	A sziták eredményeinek ellenőrzése	34
		3.3.8.	Adatbázis műveletek	34
		3.3.7.	Parancssor	34
		3.3.6.	Grafikus megjelenítés	33
		3.3.5.	gui.ui	33
		3.3.4.	gui. sieve	30
		3.3.3.	gui.io	29
		3.3.2.	gui.math	27

1. fejezet

Bevezetés

A prímszámok léte, és több velük kapcsolatos eredmény régóta ismert a matematikában. Eratoszthenész szitája, az egyik legősibb ismert algoritmus, máig hatékonynak számító módszert ad a prímek keresésére. A nagy teljesítményű számítógépek megjelenésével lehetővé vált a prímszámokkal kapcsolatos tételek és sejtések szisztematikus vizsgálata addig elérhetetlenül nagynak tűnő számokon. A számítógépes kommunikáció elterjedésével a bizonyíthatóan helyes titkosító algoritmusokra is megnőtt az igény, a modern kriptográfiai algoritmusok közül több is a prímszámok tulajdonságait használja ki.

A prímekkel kapcsolatos gyakori számítógépes feladat egy becslés pontosságának felmérése, vagy adott tulajdonságú számra példa keresése. Ilyen feladat például a prímszámtétel által adott becslés összevetése a prímek tényleges számával, nagy ikerprímek keresése[8], vagy a Goldbach-sejtés ellenőrzése[3]. Ezeknél a feladatoknál az első lépés sokszor a prímek megkeresése egy intervallumon, ez a prímsziták feladata.

Eratoszthenész szitája máig a leggyakrabban használt szita, egyszerűségének köszönhetően számítógépen futtatva sokszor gyorsabb, mint más, elméletileg gyorsabb algoritmusok. Eratoszthenész eredeti algoritmusa a prímeket egy nagy intervallumon állítja elő, ami modern számítógépek memóriájában sem férne el, így általában az intervallumot felosztják több rövidebb intervallumra, és ezeket külön szitálják. A gyors megvalósítások a rövid intervallumokat és a segédstruktúrákat a számítógép gyorsítótárának méretéhez igazítják, amivel a futási időt töredékére lehet csökkenteni egy naiv megvalósításhoz képest.

A szakdolgozat célja, hogy keretet adjon prímszita algoritmusok sebességének összehasonlítására. Megvalósítja Eratoszthenész szitájának több változatát, és Atkin szitáját[1]. Atkin szitája új algoritmus Eratoszthenész szitájához képest, a számelmélet modern eredményeit felhasználva jobb elméleti futási idővel rendelkezik, mint Eratoszthenész szitája.

2. fejezet

Felhasználói dokumentáció

A megoldott feladat

A program lehetővé teszi a prímek néhány statisztikájának ábrázolását grafikonon, és összevetését elméleti becsült értékekkel, valamint néhány különböző szita-algoritmus futási idejének megmérését, és grafikus megjelenítését. A programmal egyéb forrás-ból származó minták megjelenítése is lehetséges.

A prímszámok statisztikáinak előállításához a programhoz tartozik egy optimalizált szita-implementáció, amivel 2^{64} -ig lehet szitálni, és az eredményt rögzíteni. Az elmentett prímlistákat a program összesíti több statisztika szerint, és a megjelenítést az összesítések alapján végzi el.


A különböző szita-algoritmusok futási idejének összehasonlításához a program tartalmazza Atkin[1] szitájának egy implementációját, és Eratoszthenész szitájának néhány variációját. Ezek a sziták a prímek statisztikáinak előállításában nem vesznek részt.


A szoftver komponensei

A program két elkülönülő részből áll. A prímszámok statisztikáinak előállításához először szükséges a prímek listájának előállítása. Ehhez egy optimalizált, gyors szita C nyelven készült el. A könnyebb implementálhatóság miatt ez is két külön program, a kis számokat szitáló init, és a nagyobb számokkal dolgozó generator. Az init és a generator program a működési elvében hasonló.

A program többi része Java nyelven van megírva, ez a gui nevű program. Ez összesíti a prímek listáját, tartalmazza a futási idők összehasonlításához írt szitákat, és jeleníti meg a prímek statisztikáit, és a futási idők mintáit.

Ez a három program az "adatbázis könyvtárba" mentett bináris fájlokon keresztül kommunikál. Ide kerülnek az elkészült szitatáblák, és a prímek statisztikái.





A programok több prímszitát tartalmaznak. A prímsziták számok egy intervallumáról döntik el, hogy melyik szám prím, és melyik összetett. A legtöbb implementált szita Eratoszthenész szitájának változata. Eratoszthenész szitája az egész számok egy adott [2,n] intervallumába eső számokról dönti el, hogy melyik prím. Ezt a pq szorzatra bontható számok megjelölésével teszi, ahol a p < n prím, és $1 < q \in \mathbb{N}$. Az algoritmus sorban veszi a számokat a listában kettőtől. Ha egy addig még meg nem jelölt számot talál, akkor az prím, és a listában megjelöli annak többszöröseit, de a prímet nem. Az algoritmus futása után a meg nem jelölt számok a prímek.

```
1: n: a szitálás felső határa

2: a számok legyenek nem megjelölve, 2-től n-ig

3: for i \leftarrow 2, i \leq n, i \leftarrow i+1 do

4: if i nincs megjelölve then

5: for j \leftarrow i^2, j \leq n, j \leftarrow j+i do

6: legyen j megjelölve

7: end for

8: end if

9: end for
```

Ennek az egyszerű algoritmusnak a egyik hátránya, hogy n-ig szitálva n-1 bit memóriára van szüksége, ez a bitvektor a szitatábla. Erre megoldás a szegmentált szitálás, ahol egy rövidebb, nem feltétlenül 2-től kezdődő intervallumban szitálnak. Ehhez szükség van a prímek listájára, legalább az intervallum végének négyzetgyökéig.

A legegyszerűbb szegmentált szita egy szegmens szitáláshoz minden prímet sorban vesz az intervallum végének négyzetgyökéig, osztással meghatározza, hogy melyik a legkisebb többszöröse a szegmensben, és ha van ilyen szám, akkor onnantól összeadással szitál a prímmel a szegmens végéig, ahogy Eratoszthenész szitája is teszi.

Több, egymás utáni szegmens szitálásával az osztás költsége több szegmensre szétosztható. Ehhez a prímek listájában minden prímhez el kell tárolni a következő szitálandó többszörösét. Egy szegmens szitálása után ezt a számot frissítve a

következő szegmensben osztás nélkül folytatható a prímmel a szitálás. A módszer hátránya, hogy a prím-pozíció párok tárolásához nagyságrendileg $\mathcal{O}(\sqrt{n})$ bit szükséges, ha a legnagyobb szitált szám n. A hatékony eratoszthenészi sziták ennek a prím-pozíció listának csak azon elemeit veszik figyelembe egy szegmens szitálásakor, amik ténylegesen szitálnak is a szegmensben.

Init és generator program

A prímszámok listájának generátora elkülönül a **gui** programtól. A hatékonyabb erőforrás kihasználáshoz C nyelven készült el, és csak parancssorból futtatható.

A prímlisták generátora Eratoszthenész szitájának szegmentált változata. Minden iterációban a szitatábla egy 2^{30} hosszú darabját szitálja ki, és az eredményt az adatbázis könyvtárba menti, ezek a szegmensfájlok.

Ez a generátor önmaga is két részből áll. Az egyszerűbb implementációjú init a prímek listáját 2³²-ig állítja elő. Ezekre a prímekre nem csak a statisztikák előállítása miatt van szükség, hanem a generator, és a gui program szitái ez alapján állítják elő a belső prímlistájukat.

A gyorsabb, de összetettebb generator 2^{32} -től $2^{64} - 2^{34}$ -ig szitál, és a futásához szükséges a prímek listája 2^{32} -ig. A szitálást tetszőleges szegmenstől lehet kezdeni a megengedett tartományon belül, nem szükséges sorban végigmenni a számokon. A generator által előállított szegmensfájlokra összesítés és ellenőrzés után többet nincs már szükség.

Gui

A program többi része a Java környezethez készült, ez a gui program. Ez végzi a generator által előállított szegmensfájlok összesítését, és az elkészült statisztikák megjelenítését.

A generator a szegmensfájlokat az adatbázis könyvtáron keresztül adja át a gui programnak, és az összesítések is ebbe a könyvtárba kerülnek.

Megjelenítés

A gui képes egyváltozós mintákat megjeleníteni Descartes-féle koordináta rendszerben. A minták értékkészlete a természetes számok, az értelmezési tartomány a valós számok. Ezek a minták a szitálással gyűjtött statisztikákból származhatnak, vagy külső forrásból is betölthető minta az (x, y) párok felsorolásával.

Lehetséges a mintákat alapfüggvények lineáris kombinációjával közelíteni. Az alapfüggvényeket beépített függvényekből lehet kiválasztani, vagy JavaScript nyelven is meg lehet adni. A közelítő függvény és a minta grafikonját a program együtt

jeleníti meg, ezzel a hibát nem csak numerikusan adja meg a program, hanem szemlélteti is.

Sziták

A gui program tartalmaz több prímszita implementációt is. Ezeknek az algoritmikus bonyolultsága különböző, de a futási idejük összehasonlíthatóságához a közös részek közös implementációt kaptak, és az eltérő részek hasonló szinten optimalizáltak. A sziták helyességének ellenőrzéséhez a sziták eredménye egymással összehasonlítható.

Elkészült Eratoszthenész szitájának több változata, mindegyik szegmentáltan működik, a különbség a prímek listájának kezelésében van. A legegyszerűbben implementált eratoszthenészi szita a prímek listáját minden szegmensben végig bejárja. A prioritásos soron alapuló sziták a prímeket részlegesen rendezik az alapján, hogy a prím melyik szegmensben szitál legközelebb. Ilyen a bináris kupacot, és az edénysort használó szita.

A Cache Optimalizált Lineáris Szita[2] a prímeket teljesen rendezi az alapján, hogy legközelebb melyik szegmensben fognak szitálni, és a prímek nagyság szerinti csoportosításával a rendezés fenntartásához az elemek memóriabeli mozgatását is kerüli.

Atkin szitája[1] az előbbi algoritmusoktól jelentősen eltér, a prímek többszörösei helyett $n=ax^2+by^2$ egyenlet megoldásait keresi egy n szám vizsgálatához, x és y pozitív egészek befutásával, a és b egész konstansok. A pontos kvadratikus formát, és x és y lehetséges értékeit Atkin az egészek algebrai bővítésével határozza meg, $n\in 4\mathbb{Z}+1$ esetén a Gauss-egészek, $n\in 6\mathbb{Z}+1$ esetén az Eisenstein-egészek, és $n\in 12\mathbb{Z}+11$ esetén a $\mathbb{Z}[\sqrt{3}]$ segítségével.

A sziták között kapott helyet a próbaosztás, és a Miller–Rabin pszeudoprím teszt [5] is, de ezek a lassúságuk miatt csak igen rövid tartományokon használhatóak. A próbaosztás egy faktorizációs eljárás, ami egyetlen számot nem-triviális szorzatra próbál bontani. Az (erős) pszeudoprím teszt egy prímteszt, egyetlen számról próbálja eldönteni, hogy az prím-e. A prímteszteket általában több nagyságrenddel nagyobb számokra alkalmazzák, mint a szitákat, és teljes módszer helyett sokszor megelégednek egy valószínűségi válasszal.

A program telepítése és futtatása

A program futtatásához Windows vagy Linux operációs rendszer szükséges, legalább 4GB szabad memóriával. A Java program futtatásához JRE8 szükséges, a fordításához JDK8. A C program fordításához C99 szabványú fordítóprogram kell. A program fejlesztése és tesztelése OpenJDK8-cal és GCC 7.3-mal történt Linux

operációs rendszeren.

A teljes program letölthető a https://github.com/zooflavor/lazysieve címről, vagy megtalálható a CD mellékleten. A CD mellékleten található tarball a Java programot lefordítva is tartalmazza, kicsomagolás után azonnal futtatható. A C programot a generator könyvtárban található Makefile segítségével lehet lefordítani:

```
generator$ make clean build
```

A Java program a NetBeans 8-as verziójával készült, parancssorból a project ant fájlának segítségével lehet újrafordítani:

```
gui$ ant clean jar
```

A program futtatásához több előkészített szkript is rendelkezésre áll, ezeket mind a scripts könyvtárból lehet indítani. Az előző két fordítást egyben is el lehet végezni a recompile szkripttel:

```
scripts$ ./recompile
```

Prímek keresése

A prímek keresését két program végzi, az init program 2^{32} -ig keresi meg és tárolja el a prímeket, a generator 2^{32} -től $2^{64} - 2^{34}$ -ig. Az init készítette szitattáblák a generator futásához szükségesek.

Mindkét program a számokat 2^{30} hosszú táblánkként szitálja, minden tábla első száma $k \cdot 2^{30} + 1$ alakú, ahol $k \in \mathbb{N}_0$ és $k < 2^{34} - 2^4$. A szitatáblában csak a páratlan számok vannak nyilvántartva. A szitatáblákat a programok a fájlrendszerben bitvektorként tárolják, egy tábla kb. 64Mb.

Az első négymilliárd szám szitálása a következőképpen indítható el:

Ennek eredmény 4 bitvektort tartalmazó bináris fájl, amit a db mappába ment. Ez a négy fájl rövid idő alatt újragenerálható, de ezeket érdemes megtartani, a generator és a gui programnak is szüksége van rá.

A generator programot többféleképpen is lehet indítani. Mindegyik esetben két paramétert kell megadni az indításhoz, a számot, ahol a szitálást kezdje, és a szegmensek számát, amit ebben a futásban végig kell szitálni. A szegmensek számát kétféleképpen lehet szabályozni. Az egyik lehetőség fix számú szegmens megadása.

```
generator$ ./generator.bin ../db start 0x100000001 segments 3 szegmens kezdet: 4 294 967 297 szegmensek száma: 3 kis szegmensek mérete: 22 elágazások bitjei: 8
```

```
felkészülés 1/4
felkészülés 2/4
felkészülés 3/4
felkészülés 4/4
felkészülés vége
szegmens 4 - kezdet 4 294 967 297 - felkészülés 8 162 031 487 ns - szitálás 729 914 370 ns
szegmens 5 - kezdet 5 368 709 121 - felkészülés 418 ns - szitálás 736 412 117 ns
szegmens 6 - kezdet 6 442 450 945 - felkészülés 385 ns - szitálás 750 022 409 ns
összes szitálás 2 216 348 896 ns
```

A másik mód a háttértáron fenntartandó szabad hely átadása, ezt bájtokban kell megadni. Ekkor a generator minden szegmens szitálása előtt megvizsgálja, hogy van-e még annyi szabad hely az adatbáziskönyvtárban, mint amennyi meg van adva, ha igen, akkor szitálja a szegmenst, és lép a következőre szegmensre. Ha nincs már elég szabad hely, akkor a program leáll.

```
generator$ ./generator.bin ../db start 0x100000001 reserve-space 1000000000 szegmens kezdet: 4 294 967 297 fenntartandó hely: 1 000 000 000 byte kis szegmensek mérete: 22 elágazások bitjei: 8 felkészülés 1/4 felkészülés 2/4 felkészülés 3/4 felkészülés 4/4 felkészülés 4/4 felkészülés 4/4 felkészülés vége szegmens 4 - kezdet 4 294 967 297 - felkészülés 8 162 031 487 ns - szitálás 729 914 370 ns szegmens 5 - kezdet 5 368 709 121 - felkészülés 385 ns - szitálás 736 412 117 ns szegmens 6 - kezdet 6 442 450 945 - felkészülés 385 ns - szitálás 750 022 409 ns összes szitálás 2 216 348 896 ns
```

Mindkét program kimenetében a "start" a szegmens kezdőszáma, a "szegmens" az indexe, $start = szegmens \cdot 2^{30} + 1$, a "felkészülés" a szita inicializálási ideje a szitálás előtt, és a "szitálás" a szegmens szitálásának ideje. Ezek az információk az elmentett szegmensfájlokból is kiolvashatóak.

A generator program minden olyan paraméterét, ami szám, meg lehet adni decimálisan, és hexadecimálisan is 0x előtaggal. A számok kétféle megadásának lehetősége a gui programot hívó szkripteknél is megvan.

Az adatbázis karbantartása

A init és generator programok az elkészült szitatáblákat az adatbáziskönyvtárba mentik. Minden szitatábla külön "szegmensfájlba" kerül. A szegmensfájlok neve primes.-szal kezdődik, és pontosan 16 hexadecimális karakter követi. Ez a 16 jegyű szám a szegmens első száma. A fájl a páratlan számok bitvektora mellett tartalmazza a szegmens szitálásának megkezdésére, és a szitálására fordított időt, valamint ellenőrzésképpen a szegmens kezdőszámát is.

A szitatáblák mellett az adatbázis tartalmazhatja szegmensek összesített statisztikáit is, **aggregates** néven. Ez a fájl az eddig összesített szegmensekről a következő információkat tartja nyilván, minden szegmensről külön-külön:

• a szegmens kezdőszáma

- a szegmens szitálására való felkészülés idejét
- a szegmens szitálásának idejét
- az összesítésre fordított időt
- a szegmensfájl utolsó módosítási idejét
- a szegmensbe eső legkisebb, és legnagyobb prímet
- \bullet a szegmensbe eső $4\mathbb{Z}+1,\ 4\mathbb{Z}+3,\ 6\mathbb{Z}+1$ és $12\mathbb{Z}+11$ alakú prímek számát külön-külön
- a szegmensben előforduló prímhézagok első előfordulásának helyét, és az előfordulások számát.

A szegmensbe eső összes prím számát nem tárolja a szegmensstatisztika. Az összes páratlan prím számát megadja a 4Z+1 és a 4Z+3 alakú prímek számának összege. Az összes prím számához az 1-től kezdődő szegmensnél még az egyetlen páros prímet, a 2-t, hozzá kell számolni.

Példaként ha a szegmensek mérete 16 szám lenne, és 17-től szitálnánk egy szegmensnyit, akkor a szegmensfájl leírná, hogy a prímek a 17, 19, 23, 29, 31, és az összetett számok a 21, 25, 27. A szegmens összesítése azt tartalmazná, hogy

- a szegmens 17-tel kezdődik
- a legkisebb prím 17, a legnagyobb 31
- a szegmensben
 - $-2db 4\mathbb{Z}+1$
 - $-3db 4\mathbb{Z} + 3$
 - $-2db 6\mathbb{Z} + 1 \text{ és}$
 - -1db $12\mathbb{Z} + 11$ alakú prím van
- a szegmensben előforduló prímhézagok
 - a 2 (ikerprímek) kétszer fordul elő, először 17-nél
 - a 4 egyszer fordul elő, először 19-nél
 - a 6 egyszer fordul elő, először 23-nál.

Adatbázis műveletei

Az adatbázison három művelet végezhető:

- Le lehet kérni
 - a szegmensfájlok számát
 - az első és utolsó szegmensfájlt
 - az legkisebb hiányzó szegmensfájlt
 - a szegmensstatisztikák számát
 - az első és utolsó szegmensstatisztikát
 - az legkisebb hiányzó szegmensstatisztikát
 - az összesítést igénylő új szegmensfájlok számát.
- Összesíteni lehet az új szegmensfájlokat.
- Össze lehet fésülni két összesítőfájlt.

Mindhárom művelet elvégezhető a grafikus felületen, és automatizáláshoz parancssorból is. A grafikus felületet a gui szkripttel lehet indítani, a parancssorból a database szkript segítségével lehet elérni a műveleteket.

A gui programnak az adatbázis könyvtár helye ugyanúgy paraméter, ahogy az init-nek és a generator-nak. Ezt a könyvtárat a gui és a database szkriptek beégetve tartalmazzák, ezt nem kell külön megadni. A beégetett könyvtár a ../db. Szükség esetén ez a könyvtár a szkriptek egyszerű módosításával megváltoztatható, a DB változónak adott érték átírásával.

Adatbázis információk

A adatbázis információkat a grafikus felületen a "DB info" gomb megnyomásával lehet lekérdezni, parancssorból a database info kiadásával.

```
scripts$ ./database info
100.0%
szegmensfájlok: szegmensek száma: 7
szegmensfájlok: első szegmens kezdete: 1
szegmensfájlok: utolsó szegmens kezdete: 6,442,450,945
szegmensfájlok: első hiányzó szegmens kezdete: 7,516,192,769
szegmensfájlok: hiányzó szegmensek száma: 18,446,744,073,709,551,593
összesítések: szegmensek száma: 62,881
összesítések: első szegmens kezdete: 1
összesítések: utolsó szegmens kezdete: 67,516,885,893,121
összesítések: első hiányzó szegmens kezdete: 67,517,959,634,945
összesítések: hiányzó szegmensek száma: 18,446,744,073,709,488,719
új szegmensfájlok: 7
scripts$ ./database info crunch 1024
```

```
100.0% szegmensfájlok: szegmensek száma: 4 szegmensfájlok: első szegmens kezdete: 1 szegmensfájlok: utolsó szegmens kezdete: 3,221,225,473 szegmensfájlok: első hiányzó szegmens kezdete: 4,294,967,297 szegmensfájlok: hiányzó szegmensek száma: 18,446,744,073,709,551,596 összesítések: szegmensek száma: 140,292 összesítések: első szegmens kezdete: 1 összesítések: utolsó szegmens kezdete: 150,636,314,230,785 összesítések: első hiányzó szegmens kezdete: 150,637,387,972,609 összesítések: hiányzó szegmensek száma: 18,446,744,073,709,411,308 crunch: ../generator/generator.bin ../db start 0x890100000001 segments 0x400
```

A crunch paraméter és a szitálni kívánt szegmensek számának megadásával az utolsó sorban a következő futtatásra ajánlott parancsot is megjeleníti a program. Ezeknek a parancsoknak a követésével a teljes szitálható tartományt fel lehetne dolgozni. A crunch-numbers szkript ezt a feladatot kísérli meg elvégezni.

A database info megjeleníti az új szegmensfájlok számát is, ezek azok, amikhez vagy nem tartozik összesített adat, vagy tartozik, de az régebbi szegmensfájl alapján készült, mint ami éppen az adatbáziskönyvtárban található.

2.2. ábra. Adatbázis információk								
szegmensfájlok								
szegmensek száma	4							
első szegmens kezdete	1							
utolsó szegmens kezdete	3,221,225,473							
első hiányzó szegmens kezdete	4,294,967,297							
hiányzó szegmensek száma	18,446,744,073,709,551,596							
összesítések								
szegmensek száma	140,292							
első szegmens kezdete	1							
utolsó szegmens kezdete	150,636,314,230,785							
első hiányzó szegmens kezdete	150,637,387,972,609							
hiányzó szegmensek száma	18,446,744,073,709,411,308							
<u>O</u> k								

Szegmensek összesítése

Az adatbázis könyvtárban található új szegmensfájlokat a "DB összesítés" gomb megnyomásával, vagy a database reaggregate paranccsal lehet összesíteni. Minden olyan szegmensfájlról új összesítés készül, amihez még nem tartozott összesítés, vagy a szegmensfájl újabb, mint ami alapján a már meglévő összesítés készült. Az adatbázisban már meglévő, többi szegmenshez tartozó statisztika nem vész el.

Összesítőfájlok összefésülése

Lehetőség van egy másik adatbázisból statisztikák átvételére is. Erre több gépen párhuzamosan szitálva lehet szükség. Az összefésülést a grafikus felületen a "DB import" megnyomása után egy file kiválasztásával lehet indítani. Parancssorból a dabatase import aggregates fájlnév parancs kiadásával. A megadott fájlból azokat a szegmenseket veszi át a program, amik vagy nincsenek még meg az adatbázisban, vagy megvannak, de az importált statisztikák utolsó módosítási ideje nagyobb az adatbázisban lévőnél.

```
scripts \$ ./database import aggregates /valahol/egy/masik/aggregates 100.0%
```

Az init és a generator eredményeinek ellenőrzése

Az init és a generator program teszteléséhez a gui program képes a szegmensfájlok ellenőrzésére. Ehhez a gui újra előállítja az ellenőrzött szegmensfájlokat, és azokat összeveti az adatbázis könyvtárban találhatóakkal. Az ellenőrzőszegmensek előállításához az egyszerű szegmentált eratoszthenészi szitát, vagy ez erős pszeudoprím tesztet lehet választani.

A pszeudoprím teszt a szegmens minden számáról egyesével dönti el, hogy az prím-e. A pszeudoprím teszt rendkívül lassú, a célja, hogy Eratoszthenész szitájához képest egy alapvetően más módszer is rendelkezésre álljon az ellenőrzéshez.

A grafikus felületen a "Szegmensfájlok ellenőrzése" gomb megnyomása után lehet kiválasztani a szitálni kívánt szegmenseket, és a referencia előállításának módszerét, majd az "Ellenőrzés" gombbal lehet megkezdeni a tényleges folyamatot.

Az ellenőrzést parancssorból is lehet futtatni a check-segments szkripttel. A szkript első paraméterében a referencia módszerét várja, ami lehet sieve, vagy test, a paraméterek maradéka az ellenőrizendő szegmensek kezdőszáma kell legyen. Ha egy kezdőszám sincs megadva, akkor a program az adatbázis könyvtárban található összes szegmensfájlt ellenőrzi.

```
scripts$ ./check-segments sieve
100.0%: A szegmensek helyesek.

scripts$ ./check-segments sieve 0x1 0xc0000001
100.0%: A szegmensek helyesek.

scripts$ ./check-segments test 0x1
100.0%: A szegmensek helyesek.
```

Az ellenőrzőszegmens szitával történő előállításához szükséges, hogy az init program által előállított négy darab szegmensfájlt tartalmazza az adatbáziskönyvtár. Az 1-től kezdődő szegmens kivételével az ellenőrző szegmens előállításához a szita az inicializálásához a prímszámokat innen olvassa fel.

A gui szitáinak ellenőrzése

A sziták futási idejének összehasonlításához írt szitákat is lehet ellenőrizni, az általuk előállított szitatáblák ellenőrzésével. Ezek a szitatáblák csak a gui memóriájában vannak, az adatbázis könyvtárba nem kerülnek be. Az összehasonlításhoz a szegmensek ellenőrzésénél használt egyszerű szegmentált szita a referencia.

A program grafikus felületén a "Sziták ellenőrzése" lehetőséget választva ki kell választani az ellenőrizendő szitát, és az ellenőrizni kívánt intervallum kezdő és végző számát. A folyamat az "Ellenőrzés" gomb megnyomásával indítható.

Parancssorból is ellenőrizhetőek a sziták a **check-sieve** szkripttel. A szkript 3 paramétere a szita neve, és az intervallum kezdő-, és végszáma. Az ellenőrizhető sziták nevei:

• atkin: Atkin szitája[1]

• cols: Cache Optimalizált Lineáris Szita[2]

- eratosthenes-segmented: Eratoszthenész szitájának szegmentált változata
- bin-heap és bin-heap-inplace: Eratoszthenész szitája bináris kupaccal, a bin-heap-inplace a kupac javítását helyben végzi
- buckets, buckets-n, buckets-simple: Eratoszthenész szitája, edénysorral A buckets-simple nem szegmentált, a buckets, és a buckets-n szegmentált. A buckets-n-ben az n helyére 1-től 8-ig a számrendszer bitjeinek számát lehet megadni, például a buckets-3 8-as számrendszerben számol
- trial-division: próbaosztás

A 38 oldalon található "Sziták" szakaszban található ezeknek a szitáknak a részletesebb leírása.

A sziták nevei listázhatóak a list-sieves szkripttel, a describe-sieves szkript rövid leírást is ad.

scripts \$./check-sieve buckets-3 300000000001 301000000001 100.0%: A szita helyes.

2.3. ábra. Szita ellenőrzése

Ellenőrzés

Bezár

Atkin szitája

Kezdőszám:

Végszám:

1,073,741,825

1

14

Ha a kezdőszám nagyobb, mint 1, az ellenőrzéshez ilyenkor is szükséges, hogy a négy darab kezdő szegmensfájlt tartalmazza az adatbáziskönyvtár.


Minta megjelenítése

A gui program a grafikus felületén képes mintákat Descartes-féle koordináta rendszerben ábrázolni, a mintákat függvényekkel közelíteni, és ezeket a függvényeket a mintával együtt ábrázolni. A program a közelítések négyzetes hibáját is kiszámítja a mintához képest. A program egyváltozós, egyértékű mintákat kezel, azok között is a természetes számokhoz valós számokat rendelőket. A minta akár külső forrásból is származhat.

A grafikonábrázoló részt a gui-graph szkripttel lehet indítani. A gui szkripttel indítva, majd a "Grafikon" gomb megnyomásával is meg lehet nyitni ezt az ablakot.

Az ablak bal oldalán jelennek meg a betöltött minták és közelítő függvények grafikonjai. Minta és függvény hozzáadása után a grafikon megjelenített részét a program úgy választja meg, hogy minden minta összes pontja ebbe a nézetbe essen. A nézet a grafikon feletti gombokkal, vagy egérrel mozgatható, nagyítható, vagy kicsinyíthető. Az "Auto.nézet" gombbal a nézet a minták teljes terjedelmére visszaállítható.

Az ablak jobb oldala a betöltött minták kezelésére szolgál. A felső harmada az összes betöltött mintát mutatja. Az ablak jobb oldalának alsó két harmadában az itt kiválasztott minta részletei látszódnak.



2.4. ábra. Minta megjelenítése

Minta hozzáadása

A "Minta hozzáadásánál" három adatforrásból lehet választani. A "Fájl betöltésével" CSV fájl olvasható be. A fájl formátuma megengedő, az első oszlopot x, a

második oszlopot y értékeknek próbálja értelmezni, a fel nem ismert sorokat eldobja. Ha az első sor első oszlopában BARS szerepel, akkor a program a mintát vonaldiagram helyett oszlopdiagramként fogja ábrázolni.

A "Prímstatisztikák" a generator kimeneteléből összesített statisztikák. Ezeket a gui program az adatbáziskönyvtárban keresi. A program a szegmensstatisztikák hiánytalan kezdőszeletét veszi csak figyelembe. A statisztikáknak három csoportja van.

- A prímek száma, és néhány kiemelt alakú prím száma minden szegmens végén.
 Ide tartozik a prímszámtétel becslése, és a becslés abszolút és relatív hibája is.
- A prímhézagok statisztikái a szegmensek teljes kezdőszeletére vonatkoznak, az értékek az első szegmenstől a kezdőszelet végéig összesített statisztikából származnak. A prímhézagok statisztikái az előfordult hézagok gyakorisága, első előfordulása, jósága, valamint a legnagyobb prímhézag adott számig.
- Ezeken kívül a szegmensek szitálásának ideje is betölthető. A szegmensenkénti idő minden szegmens végéhez annak a szegmensnek a szitálásának idejét rendeli. Az összesített idő a szegmensek végéig az összes megelőző szegmens szitálásának idejét adja össze.

A minták harmadik forrása a programba épített sziták futási idejének mérése. Ehhez meg kell adni a szitát, a szitált intervallum elejét és végét, a szita belső szegmensméretét, a generálandó mintaelemek számát, a mérések számát, a mértéket, és hogy az eredményt összesítse-e.

 Mérés
 Bezár

 Atkin szitája
 ✓

 Kezdőszám:
 4,294,967,297 →

 Végszám:
 17,179,869,185 →

 Szegmens méret:
 1,048,576 = 2^20 →

 Minták száma:
 1,000 →

 Mérések száma:
 3 →

 Mérték:
 nanoszekundum

 V Összesítve

2.5. ábra. Szita futási idejének mérése

A sziták listája megegyezik a 14 oldalon található "A gui szitáinak ellenőrzése" szakasz szitáival. A mintavételezés pontjait a program a szitált intervallumon egyenletesen osztja el a megadott méretű szegmensek határainál. A teljes szitálást

annyiszor végzi el, amennyi a mérések számában meg volt adva, és az eredményt átlagolja. Összesítést kiválasztva a mintaelemek értéke a szitált intervallum elejétől az adott számig szitálás teljes ideje, különben az előző mintavétel helyétől. A mérték szabályozza, hogy a tényleges eltelt időt mérje a program nanoszekundumokban, vagy az elvégzett műveletek számát.

Minta közelítése

Az ablak jobb oldalának középső harmadában a kiválasztott minta részletei látszódnak. Itt változtatható meg a minta ábrázolásához használt szín, távolítható el a minta, vagy menthető CSV fájlba.

A táblázat a minta közelítéseit mutatja, itt olvashatóak le a közelítés elemi függvényei, és a közelítés hibája. A "Közelítés" gombbal lehet új közelítést hozzáadni az ábrázoláshoz. A közelítéshez a lineáris legkisebb négyzetek módszerét használja a program, ehhez a lineáris kombináció elemi függvényeit meg kell adni. A függvények kiválaszthatóak az előre megadott listából, vagy JavaScript nyelven is megadhatóak. A közelítéshez csak olyan függvények használhatóak, amik a minta minden pontjában értelmezve vannak.

<u>O</u>k <u>M</u>égsem In(In(x)) 1/ln(ln(x)) sqrt(x) 1/ln(x) $= x/(\ln(\ln(x))*\ln(x))$ X In(x) x/ln(ln(x)) x^2 1/x In^2(x) 1/x^2 x/ln(x) x*In(In(x) x/ln^2(x) x^2/ln(ln(x)) x^5 x*In(x) x^6 x*In(x)*In(In(x)) x^2/ln(x) x*In^2(x) Script fv. hozzáadása Script fv. eltávolítása log*

2.6. ábra. A közelítés elemi függvényeinek megadása

JavaScript függvényhez meg kell adni a függvény nevét és forráskódját. A forráskódban a függvény argumentumára az x változóval lehet hivatkozni, és a szkript utolsó kifejezésének értéke lesz a függvény helyettesítési értéke x-ben. Például az $x\mapsto \frac{\ln x}{x}$ hozzárendelés forráskódja:

Math.log(x)/x

A szkriptben használható változó, és a szokásos vezérlőutasítások. Például az iterált logaritmus egy megadása:

```
var y=0;
while (1<x) {
   x=Math.log(x);
   ++y;
}
y</pre>
```

Az így megadott függvények visszatérési értéke mindig double típusú kell legyen, és a függvény azokban a pontokban értelmezett, ahol ez az érték véges.

Egy kiválasztott közelítés részletei az ablak jobb alsó sarkában látszódnak, itt megváltoztatható a közelítéshez rendelt szín, és eltávolítható a közelítés. A táblázat a közelítéshez kiválasztott függvények együtthatóit mutatja a lineáris kombinációban.

A legkisebb négyzetek módszerének feladata röviden leírható. Ha az n elemű minta $(x_1, y_1), (x_2, y_2), \ldots, (x_n, y_n)$ (ahol $x_i \in \mathbb{N}, y_i \in \mathbb{R}$) és a közelítéshez kiválasztott m függvény f_1, f_2, \ldots, f_m $(f_i : \mathbb{R} \mapsto \mathbb{R})$, akkor a legkisebb négyzetek módszere keresi azokat a c_1, c_2, \ldots, c_m $(c_i \in \mathbb{R})$ skalárokat, hogy az

$$f(x) = \sum_{i=1}^{m} c_i f_i(x) \ (x \in \mathbb{R})$$

közelítő függvény és a minta eltérése minimális legyen a

$$\sum_{i=1}^{n} (f(x_i) - y_i)^2$$

négyzetes eltérés összeg szerint.

A program ezt az eltérés összeget jeleníti meg a közelítés hibájaként, valamint a c_i skalárokat a közelítés elemi függvényeinek együtthatóiként.

Sziták futási idejének mérése szkriptekkel

A sziták futási idejének mintáit parancssorból is elő lehet állítani. Ilyenkor az eredményt, megjelenítés helyett, a megadott CSV fájlba írja a gui program, ami később a grafikus felületen betölthető. A méréseket a measure-sieve szkripttel lehet elvégezni, paraméterként meg kell adni ebben a sorrendben:

- a szita nevét, ezek ugyanazok lehetnek, mint a 14 oldalon a "A gui szitáinak ellenőrzése" szakaszban
- a számot, ahol a szitálás kezdődik, ez páratlan szám kell legyen

- a szitálás végét, ez páratlan szám kell legyen
- a szegmensek méretét
- a mérések számát
- a minták számát
- hogy időt (nanosecs), vagy műveleteket (operations) mérjen
- összesítse az időket (sum), vagy szegmensenként külön számolja (segment)
- a fájlt, ahova az eredményt mentse

Ha a kezdőszám nagyobb, mint 1, akkor az adatbáziskönyvtárnak tartalmaznia kell az init program generálta első négy szegmenst.

Lehetőség van a mérték és az összesítés mind a négy kombinációját egy méréssel előállítani, ehhez mind a négy kimeneti fájlt meg kell adni.

```
scripts$ ./measure-sieve buckets-3 1 0x10000001 0x10000 3 1000 nanosecs sum out1.csv
100.0%
scripts$ ./measure-sieve buckets-3 1 0x10000001 0x10000 3 1000 operations segment out2.csv
100.0%
scripts$ ./measure-sieve buckets-3 1 0x10000001 0x10000 3 1000
seg-ns.csv seg-ops.csv sum-ns.csv sum-ops.csv
100.0%
```

A mérések megkönnyítéséhez a measure-sieves szkript az összes szitát megméri, és az eredményt a samples könyvtárba menti. A samples könyvtárban a mérési eredmények 4 külön könyvtárban szegmensenként/összesítve, és idő/művelet szerinti bontásban vannak. Ezekben a könyvtárakban 2 fajta mérés eredményei vannak. Az atkin könyvtárban Atkin szitájának sebessége van megmérve különböző szegmensméretek esetén. Azokban könyvtárakban, amiknek a neve speed-del kezdődik, az összes szita sebességének mérése található, 2^{20} szegmensmérettel. A könyvtárak nevében a szám a szitálás kezdetét adja meg, a speedn nevű könyvtárban a mérések $2^n + 1$ -től kezdődnek. A lassabb szitákat csak kisebb nagyságrendekre méri meg a szkript, ezek futási ideje hamar túl naggyá válik.

A generator futási idejének mérése

A measure-generator szkript a generator program sebességét méri meg. A mérés 3 paramétert variál, a szitálás kezdetének nagyságrendjét, a szegmensméretet, és az edénysor számrendszerét. Az eredményt a samples/measure-generator.csv fájlba menti. Ez nem használható a program mintamegjelenítésével, mert az egy változós mintákkal dolgozik. Ennek a mérésnek a célja az, hogy a generator program paramétereit egy konkrét számítógéphez lehessen igazítani. A szkript 16 egymás utáni szegmensfájlt szitál, és

- $\bullet\,$ a szitálás kezdetét 2^{33} -től 2^{63} -ig változtatja, a kitevőt hármasával növelve
- $\bullet\,$ a szegmensek méretét 2^{16} -tól 2^{24} -ig, a kitevőt egyesével növelve
- \bullet és a számrendszert $2^1\text{-től }2^8\text{-ig},$ szintén a kitevőt egyesével növelve.

3. fejezet

Fejlesztői dokumentáció

A fejlesztői dokumentáció áttekintést ad a megvalósításban felhasznált módszerekről, a fejlesztés során hozott döntésekről, valamint a forráskód felosztásáról, és legfontosabb részeiről.

Az adatbázis szerkezetének leírását követően a fejezet végigveszi a megoldást alkotó három programot. Az init és a generator program egy feladatot old meg, a prímek listájának előállítását. A gui program leírása tartalmazza a felhasznált adatszerkezeteket, a statisztikák elkészítésének részleteit, az elemi függvények illesztését a legkisebb négyzetek módszerével, és a grafikonok megjelenítését.

A megvalósított eratoszthenészi szitákat külön szakasz írja le. Ez a saját ötlet alapján készült edénysor részletes leírását is tartalmazza.

A programok tesztelésénél külön feladat volt a legkisebb négyzetek módszerénél használt numerikus algoritmusok kiválasztása.

A program komponenseinek ábrája az 5 oldalon látható.

Az adatbázis

A program adatbázisa egy egyszerű könyvtár, amin keresztül a különböző programrészek kommunikálnak. Az adatbázis két fajta fájlt tárol, a szitált szegmenseket, azaz a szitatábla bitvektorait, és a szegmensek összesítéseit. Mindkettő a szegmens első számával van azonosítva, a szegmens hossza mindig 2^{30} szám, és az $n \in \mathbb{N}_0$ megengedett kezdő szám, ha $n < 2^{64} - 2^{34}$ és $n \equiv 1 \pmod{2^{30}}$. Minden szegmens egy külön fájl az adatbázis könyvtárában. Az összes szegmensstatisztika egy fájlban van.

Az init program az első 4 szegmensfájlt írja. A generator az első 4 szegmensfájlt olvassa, és az összes többi szegmensfájlt írja. A gui az összes szegmensfájlt olvassa, és egyiket se írja, és szegmensstatisztika fájlt csak a gui használja.

Egy szegmensfájlok neve primes. előtaggal kell kezdődjön, és pontosan 16 hexa-

decimális számjegy kell kövesse, ami a szegmens által leírt első szám. A fájl bináris, a legkisebb helyiértékű bájt elöl, azaz little endian sorrendben. A tartalma:

- a szegmens elejével kezdve 2²⁹ egymást követő páratlan szám bitvektora.
 Ez 2²⁶ byte, legkisebb helyiértékű byte elöl sorrendben, minden bit egy páratlan szám összetettségét írja le. Ha a bit 1, akkor a szám összetett, ha 0, akkor a szám prím. Ha s a szegmens intervallumának kezdete, akkor az 0. bájt 0. bitje s-t írja le, a 0. bájt 1. bitje s + 2-t, a i. bájt j. bitje s + 16i + 2j-t.
- a szegmens kezdete, 8 bájt, egész
- a szegmens szitálására való felkészülés ideje, 8 bájt, egész, nanoszekundumokban
- a szegmens szitálásának ideje, 8 bájt, egész, nanoszekundumokban

Ahhoz, hogy az init és a generator program bármikor leállítható legyen, a szegmenst először a tmp.tmp ideiglenes fájlba írja, és ha ez hiba nélkül megtörtént, akkor az ideglenes fájlt átnevezi a megfelelő névre. Mivel az ideiglenes fájl ugyanabba a könyvtárba kerül, mint ahova a szegmensfájl is, így feltételezhető, hogy helyi meghajtón az átnevezés már atomi művelet.

A szegmensstatisztikák az **aggregates** fájlban vannak. A szegmensek a fájlban a kezdőszámok sorrendjében követik egymást, egy szegmensnek legfeljebb egy statisztikája lehet. A fájl bináris, a legnagyobb helyiértékű bájt elöl, azaz big endian sorrendű. A fájl fejléce:

- formátum azonosító: 0xd1d1b0b0, 4 bájt
- verziószám: 1, 4 bájt.

Ezután minden statisztika egy változó méretű blokkban van tárolva, a fájl végéig. Minden block két részből áll, az első 4 bájt a második rész mérete bájtokban. Ez a második rész a szegmensstatisztika. A statisztika gzip formátumban tömörített, kitömörítve bináris adat, aminek a formátuma:

- a szegmens összesítésére fordított idő, 8 bájt, nanoszekundumokban
- a szita inicializálásának ideje a szegmens szitálása előtt, 8 bájt, nanoszekundumokban
- az összesített szegmensfájl utolsó módosításának ideje, 8 bájt, milliszekundumokban, 1970.1.1. 00:00:00-tól
- a szegmensben található legnagyobb prím, 8 bájt

- a szegmensben található legkisebb prím, 8 bájt
- \bullet a $12\mathbb{Z}+11$ alakú prímek száma a szegmensben, 8 bájt
- \bullet a $4\mathbb{Z}+1$ alakú prímek száma a szegmensben, 8 bájt
- \bullet a $4\mathbb{Z} + 3$ alakú prímek száma a szegmensben, 8 bájt
- a $6\mathbb{Z} + 1$ alakú prímek száma a szegmensben, 8 bájt
- a szegmensben előforduló prímhézagok száma, 4 bájt. ahány prímhézag előfordult, annyiszor ismétlődik a következő három mező
 - a prímhézag nagysága, 8 bájt
 - a prímhézag előfordulásainak száma, 8 bájt
 - a prímhézag első előfordulása, 8 bájt
- a szegmens sorszáma, 8 bájt
- a szegmens vége, 8 bájt
- a szegmens kezdete, 8 bájt
- a szegmens szitálására fordított idő, 8 bájt, nanoszekundumokban.

Az összesítésfájl írása a szegmensfájl írásához hasonló. A program az adatokat először az aggregates.tmp ideiglenes fájlba írja, majd megvárja, hogy a fájl tartalma a háttértárolóra kerüljön. Utána az ideiglenes fájlt átnevezi aggregates-re. Az ideiglenes fájl kiírásának megvárásával a összesítésfájl váratlan számítógép leállás esetén is visszaállítható.

A fájl formátuma és az új fájl kiírásának algoritmusa lehetővé teszi, hogy a statisztikafájlt egyszerre lehessen sorban felolvasni, és az új eredményt sorban kiírni, úgy, hogy egyszerre csak egy statisztikát kelljen a memóriában tartani.

Az adatbázis nincs védve a párhuzamos írásoktól, és az összesítőfájl egyszerű sorban feldolgozhatósága feltételezi, hogy egy fájl kevés szegmensstatisztikát fog tartalmazni, legfeljebb kb. 10⁶ szegmensét.

Init és generator

Az init és a generator forráskódja a tarball generator könyvtárában van.

A generator egy optimalizált szita, 2^{32} -től $2^{64} - 2^{34}$ -ig képes szitálni. Az utolsó 2^{34} szám kihagyása egyszerű könnyítés, így a programban az éppen szitált szám változója sosem csordul túl.

A két program egymáshoz nagyon hasonló feladatot lát el, hasonló megoldásokkal. Mindkettő 2³⁰ hosszú intervallumokat szitál, és az eredményt szegmensfájlokba írja. Mindkettő Eratoszthenész szitáját használja. Mindkét program ezt az egyetlen feladatot oldja meg, és szkriptekkel automatizált, kötegelt futtatásra van tervezve.

Közös rész

A két program közös kódja a common.h fájl. Ez a fájl tartalmazza a konstansokat, és az eljárásokat, amik megkönnyítik a POSIX hívások használatát. A legtöbb ilyen könnyítés a hibák kezelésének elfedése, ami a kötegelt futtatáshoz illeszkedően a hiba kijelzése utáni azonnali programleállás. Az I/O műveleteket könnyítik meg a readFully()/writeFully() eljárások.

A sziták belső, kis szegmensmérete a SEGMENT_SMALL_SIZE_BITS_LOG2 konstanssal szabályozható, és a measure-generator szkript kimenete alapján egy adott géphez igazítható.

A szegmensfájlok olvasására és írásara a readSegment() és writeSegment() függvények szolgálnak.

Init

Az init program előállítja az első 4 szegmens fájlt, azaz 2^{32} -ig az összes prímet megkeresi. Ezekkel a prímekkel a többi részprogram már a $[2^{32}, 2^{64})$ tartomány tetszőleges részén tud szitálni.

A szita egy egyszerű szegmentált eratoszthenészi szita. A 2³⁰ hosszú szegmenseket több kisebb, egyenlő szegmensre osztja, és ezeket a kis szegmenseket egymás után szitálja a prímek listáján végigmenve. A prímek mellett a következő szitálás helyét is eltárolja, így nem kell minden szegmens szitálásának elején minden prímhez osztással meghatározni, hogy melyik a legkisebb szám a szegmensben, amit az oszt. Így egy kis szegmensben egy prímre a következő algoritmus fut le. Ez az algoritmus visszatérő minta a szegmentált szitákban.

```
1: p: a prím

2: q: a következő szám, amit p oszt

3: e: a szegmens vége

4: while q < e do

5: MEGJELÖL(q)

6: q \leftarrow q + 2p

7: end while
```

Az init szitájának inicializálásához a prímek listáját elő kell előállítani 2^{16} -ig, ezt a program próbaosztással végzi el.

Generator

A generator fő részei hasonlóak az init-hez. Indulása után az első 4 szegmensfájl alapján 2³²-ig minden prímhez osztással meghatározza, hogy melyik a legkisebb szám, amit oszt, és legalább akkora, mint a szitálandó szegmens kezdete. A prímeket tároló adatstruktúra szitálás közben nem érzékeny azokra az elemekre, amik az éppen szitált szegmensnél nagyobb helyeken szitálnak, így a generator az összes prímet eltárolja 2³²-ig, nem csak a szitálandó tartomány végének négyzetgyökéig.

A prímek listájának inicializálása után a nagy szegmenseket az init-hez hasonlóan kisebbekre osztja, és ezeket sorban szitálja a prímek listája alapján.

A prímek listája a generator-ban több külön adatszerkezet összessége. A prímeket az inicializálásakor 3 részre osztja a nagyságuk szerint. A 64-nél kisebb prímeket 64-bit széles bitmintákban tárolja, és ezekkel a mintákkal 64-bitesével szitálja végig a kis szegmenseket a bitenkénti vagy művelettel. A 3 és a 11, valamint az 5 és a 7 szorzata kisebb, mint 64, ezeket a párokat egyetlen 64 bites mintába fejti ki, ezeknek a mintáknak a periódusa 33, és 35. A többi prím mintájának periódusa a legnagyobb olyan szám, ami 64-nél kisebb, és a prím osztja.

A prímek, amik 64-nél nagyobbak, de a kis szegmensek hosszánál kisebbek, azaz minden kis szegmensben szitálnak, az init-hez hasonlóan egy egyszerű tömbbe kerülnek, és ugyanúgy szitál ezekkel a program, mint az init-ben.

A kis szegmensek hosszánál nagyobb prímek egy kis szegmensben legfeljebb egyszer szitálnak, és van olyan szegmens, ahol egyszer sem. A generator ezeket a prímeket egy prioritásos sorban tárolja, amiben az elemek sorrendjét a következő szegmens száma határozza meg, amiben az a prím szitálni fog. A szegmensen belüli sorrendet a sor nem veszi figyelembe. A kis szegmensekben legfeljebb egyszer szitáló prímeknek nem csak a páros többszöröseit ugorja át a szita, hanem a 3-mal és 5-tel osztható többszöröseit is kihagyja. Ezeket a többszörösöket a bitmintával szitáló kis prímek jelölik meg.

Az edénysor algoritmusának részletes leírására a 38 oldalon a "Sziták" szakaszban kerül sor. Az ott leírt távolság függvényt implementálja a bucketIndex() függvény a forráskódban. A távolságfüggvény által használt számrendszert a BUCKET_BITS konstans szabályozza, a számrendszer alapja 2^{BUCKET_BITS}. A sorhoz tartozó edények listája a buckets tömb, ennek minden eleme egy láncolt lista, ahol a listaelemek fix méretű edények.

A program futása alatt a sor elemeinek száma nem változik, de az elemek az edények között mozognak. A sor legkisebb elemeinek, azaz az aktuális szegmensben szitáló prímek megkereséséhez a lista egyik edényének minden elemét megvizsgálja. Ha egy elem az aktuális szegmensben nem szitál, akkor az elemet a sorba visszahelyezi, a távolság függvény szerint már közelebbi edénybe. Ha az elem szitál az

aktuális szegmensben, akkor elvégzi a szitálást, és az elemet visszateszi a sorba, azon pozíció szerint, ahol a prím legközelebb szitálni fog.

A 2, 3, és 5 többszöröseinek hatékony kihagyásához a prioritásos sor elemeiben a pozíció mellett el van tárolva, hogy az a pozíció melyik modulo 30 maradékosztály eleme. A nyolc szóba jöhető lehetőség közül a PrimePosition.prime mező felső 3 bitje választ. Ezt a 3 bit információt biztonsággal lehet itt tárolni, a 64 bit széles változóban a feladat határai miatt mindig csak az alsó 32 tartalmaz értékes számjegyet. Ez a 2-3-5 kerék alapú gyorsítás csak a prioritásos sorban tárolt prímekre van alkalmazva.

Gui

A program Java-ban írt része tartalmazza az összes többi funkció megvalósítását: a szegmensfájlok feldolgozását, a különböző szitákat, és a minták megjelenítését. Ezeknek a funkcióknak a többsége nem interaktív, a felhasználó a paraméterek megadása után a végrehajtást már nem tudja befolyásolni.

A forráskód ennek megfelelően három egymásra épülő szintre osztható:

- A legalsó szint a program adatszerkezeteit, algoritmusait, és fájlformátumait írja le.
- Erre építenek a felhasználói műveletek megvalósításai. Mindegyik művelethez tartozik egy eljárásként megvalósított belépési pont.
- A programkód legfelső szintje ezeket teszi a felhasználó számára meghívhatóvá, parancssorból és grafikusan is.

A grafikonmegjelenítés az egyetlen ténylegesen interaktív feladat, ennek megoldása a modell-nézet-vezérlő felosztást alkalmazza.

gui.util

A csomag néhány közismert algoritmust és adatszerkezetet tartalmaz, valamint az ezekhez szükséges funkcionális interfészek definícióit. A legtöbbnek létezik könnyen használható sztenderd könyvtári megvalósítása, de ezek referenciatípusokat használnak.

A primitív és referencia típusú értékek közötti rengeteg konverzió három problémát okoz. Feleslegesen növeli a futási időt, miközben egyetlen számítógépen eleve reménytelenül hosszú feladat 2^{64} -ig szitálni. Ezen túl megnöveli a program memóriaigényét. 2^{32} -ig kb. 2×10^8 prím van, ha egy szita csak a prím-pozíció párokat egy egyszerű tömbben tárolná, prímenként 4 bájton, pozíciónként 8 bájton, akkor

ez a tömb kb. 2,4Gb memóriát foglalna el. A program a primitív típusokon alapuló konténerekkel képes 3,5Gb memória használatával futni. A harmadik probléma az, hogy primitív érték objektummá alakítása szinte mindig új objektum létrehozásával jár, ami legtöbbször egy objektum elérhetetlenségéhez is vezet. A szemétgyűjtő ezzel járó folyamatos háttérmunkája nem csak feleslegesen növeli a futási időt, hanem kiszámíthatatlanságával megnöveli a sziták mért futási idejének zaját is.

A PrimitiveList osztály és leszármazottai az ArrayList mintájára szükség szerint növekvő vektorok. Konkrét megvalósítások a double, int, és long primitív típusokra vannak.

A BinarySearch és a QuickSort a bináris keresés és a gyorsrendezés algoritmusát valósítják meg absztrakt módon elért tömb felett. Az elemeket közvetlenül sosem érik el, az összehasonlításokat és a cseréket interfészeken keresztül végzik index alapján.

A BinaryMinHeap egy bináris kupacot megvalósító absztrakt konténerosztály, az elemek típusától függő műveleteket absztrakt metódusként határozza meg. A műveletek felteszik, hogy az elemek indexelhetőek, mint egy tömbben. A kupac egy elsőbbségi sor, a sor eleje az absztrakt rendezés szerinti legkisebb elem.

gui.math

Az UnsignedLong osztály a Java long típus előjel nélküli műveleteit valósítja meg. A Java a 8-as verziótól támogatja a primitív egész típusok előjel nélküli összehasonlítását és osztását, ez az osztály ezekre építve ad néhány segédeljárást.

A pszeudoprím-teszthez a maradékos hatványozás, Java támogatás hiányában, a kitevő bitjei alapján az ismételt szorzást és négyzetre emelést használja, míg a szorzás ehhez hasonlóan összeadást és kétszerezést. Ezeknek az algoritmusoknak a futási ideje egy-egy szám esetén elfogadható, de intervallumok szitálására nem alkalmas.

Közelítés

A gui.math csomag a legkisebb négyzetek módszerének implementációját, és annak segédosztályait is tartalmazza.

A Sum double típusú értékek véges összegeit számolja ki. A double véges pontosságának következménye, hogy nem minden szám reprezentálható double értékként, és többtagú összeg eredménye függhet a tagok összeadásának sorrendjétől, azaz az összeadások sorrendje befolyásolhatja az eredmény hibáját.

A Sum három stratégiát ad az összeadások sorrendjéből származó hiba minimalizálására. A program használata közben a felhasználó ezek közül nem tud választani,

a tesztek alapján legstabilabbnak ítélt elsőbbségi soron alapuló összegzést használja a közelítés.

A legegyszerűbb Sum.Simple egyetlen változót használva a tagokat felsorolásuk sorrendjében adja össze.

A bináris kupacot használó Sum. Priority a tagokat az elsőbbségi sorban gyűjti, majd a végső összeg kiszámításához a sorból, amíg lehet, ismételten kiveszi a két legkisebb abszolút értékű elemet, azokat összeadja, és az eredményt a sorba visszahelyezi. A végeredmény a sorban maradó érték lesz.

A Sum. Array nagyságrend szerinti részösszegeket tart nyilván, új tagot a nagyságrendjéhez tartozó részösszeghez adja hozzá. A nagyságrend a double érték IEEE 754 szabvány szerinti reprezentációjának kitevője. Ebben a reprezentációban a kitevő 11 bit hosszú, a Sum. Array így mindig 2048 részösszeget tárol.

A RealFunction interfész valóshoz valóst rendelő függvények reprezentációi, ezek lehetnek a közelítés elemi függvényei. Egy függvény a helyettesítési értékein kívül az értelmezési tartományáról is információt kell adjon. A grafikonmegjelenítő az x-tengely egy pixel által lefedett intervallumán akkor jelenít meg értéket, ha az intervallum egésze az értelmezési tartomány része.

A Functions osztály a beépített elemi függvényeket tartalmazza. Már létező függvények lineáris kombinációját a LinearCombinationFunction osztállyal lehet megadni, a mintaközelítés eredménye ilyen típusú. JavaScript-ben függvény a CustomFunction-nel adható meg. Ez a sztenderd Java beépített Nashorn JavaScript motorját használja.

A Matrix osztályban vannak megadva a valós mátrixok műveletei, mindegyik kétdimenziós double tömbökre. Az implementált műveletek a legkisebb négyzetek módszeréhez szükségesekre korlátozódnak, ezek a mátrixszorzás, a transzponálás, és mátrix formában megadott lineáris egyenletrendszerek megoldása.

Lineáris egyenletrendszerek megoldhatóak a Householder-féle QR felbontással, vagy Gauss-eliminációval. A Gauss-eliminációnál kiválasztható, hogy részleges sorcserére, vagy teljes sor és oszlopcserére kerüljön sor. A Solver interfész a választott módszer részleteinek elfedésére szolgál. A közelítések tesztjei alapján a legkisebb hibát eredményező választás a Gauss-elimináció teljes sor és oszlop cserével, a felhasználó nem tudja megválasztani a lineáris egyenletrendszerek megoldási módszerét.

A LeastSquares osztályban lett megvalósítva a legkisebb négyzetek módszere. A csomag eddig felsorolt osztályaival itt lehet megadni a közelítéshez az elemi függvényeket, az összegzések és az egyenletrendszer megoldásának algoritmusát, és a közelítendő mintát. A közelítés hibáját is ki lehet ezzel az osztállyal számolni.

gui.io

A gui.io csomagban az adatbázis kezelését leíró osztályok vannak. Az adatbázis funkciók a Database egy objektumán keresztül érhetőek el, ez a common.h-val párhuzamosan definiálja a szegmensfájlok neveit, és formátumát. A felhasználói műveletek közül az adatbázis információk lekérését, a szegmensfájlok összesítését, és összesítés importálását a Database osztály info(), reaggregate(), és importAggreagtes() metódusai valósítják meg.

A sziták az inicializálásukkor a Database.largePrimes() metódust használva olvassák be az első 4 szegmensfájlból a prímeket.

A Segment osztály példányai a 2³⁰ hosszú szitatáblák. Ezek fájlból olvasott adatokat is tartalmazhatnak, vagy szegmensek és sziták ellenőrzésekor a gui program is generálhatja. Ezzel az osztállyal szegmensfájlt csak olvasni lehet, írni nem.

Ez a csomag tartalmazza a CSV fájlok olvasásához és írásához a CSVReader és CSVWriter osztályokat. Mindkettő adatfolyamként teszi lehetővé a szöveges cellák soronkénti feldolgozását.

Összesítő

Az összesítés megvalósítása a gui.io csomag része.

Egy szegmens összesítését a Segment.aggregate() függvény végzi. Az eredményül kapott Aggregate példány az adatbázis formátumánál leírt szegmensstatisztika tükre. Az összesítőfájlt az AggregatesReader és AggregatesWriter osztállyal lehet olvasni és írni. A szegmensek összesítései szigorúan növekedő kezdőszámú sorrendben dolgozhatóak fel. A írás és az olvasás AggregateBlock példányokkal dolgozik, ezek az objektumok a statisztikához való hozzáférés mellett a betömörített bináris adatot jegyzik meg, hogy a statisztika változatlan kiírása esetén ki lehessen hagyni az időigényes betömörítést.

A megjelenítésre szánt mintákat az **Aggregates** osztály készíti el a szegmensenkénti statisztikák alapján közvetlenül a megjelenítés előtt. A szegmenseket az összesítésfájl sorrendjében dolgozza fel, az első hiányzó szegmensig. A megjelenített statisztikák legtöbbje egyszerűen összesíthető a szegmensenkénti adatokból.

Az összes páratlan prím számát a 4Z + 1 és a 4Z + 3 alakú prímek számának összege adja, az összes prímet ezek mellett az egyetlen páros prím, a 2, alkotja.

Az egymás utáni szegmenseken átívelő prímhézagok egyik hézagokra vonatkozó statisztikában sem szerepelnek, ezeket a szegmensenként eltárolt legkisebb és legnagyobb szegmensbe eső prím alapján külön meg kell határozni.

gui.sieve

Ebben a csomagban, és a gui.sieve.eratosthenes alcsomagjában, a futási idők méréséhez implementált sziták vannak.

A sziták a Sieve osztály leszármazottai. A példányaitól elvárás, hogy

- a szitálást szegmensenként végzi
- a szitatábla bitvektorát csak korlátozottan éri el
 - csak az éppen szitált szegmensbe eső számokat éri el
 - páros számot sose ér el
 - legfeljebb $2^{32} 1$ -ig olvassa vissza a szitálás eredményét
- \bullet a szegmens mérete szabályozható, a lehetséges értékek a kettő hatványai 2^8 -tól 2^{30}-ig
- inicializáláskor a szitálás kezdő számáig beolvassa a prímek listáját az adatbáziskönyvtárból
- \bullet a szitálás kezdetétől 2^{32} -ig a prímeket a prímek listájába az éppen szitált szegmensből veszi
- bármikor inicializálható a szita egy szegmens kezdetéhez úgy, hogy onnantól már további felkészülési idő nélkül lehet több egymás utáni szegmenst szitálni
- az OperationCounter osztály segítségével számon tartja a szitálás műveletigényét.

3.1. ábra. A sziták osztály diagramja Operation CounterSieve TableLongTable +add()+clear(prime) +get()::long+flip(number) Segment +increment() +isPrime(number)::boolean +reset() +setComposite(number) +setPrime(number) Sieve**TrialDivision** +reset(start) +sieve() SieveOfAtkin SieveOfEratosthenes Segmented SieveQueueSieve Eratos then esian SieveCacheOptimizedLinearSieve BucketSieveSimpleBucketSieve

A SieveTable osztály Segment implementációja az adatbázisnál is használt szegmensfájl, szita ellenőrzésekor ez a szitatábla tárolja a bitvektort, és az ellenőrzés a végeredményt hasonlítja össze a referenciaszita eredményével. A Segment mindig pontosan 2³⁰ hosszú szitatáblát reprezentál.

BucketNSieve

Bucket1Sieve

A LongTable megvalósítást a program a futási idő mérésénél használja. A LongTable a teljes szitálható tartomány lefedi. 2^{32} -ig minden páratlan számhoz tartozó bitet nyilvántart. Az összes 2^{32} -nél nagyobb számhoz tartozó bit módosítása egy tömbbe képződik le. Ez a tömb 2^{26} bitet tárol. Egy számhoz tartozó bit módosításánál a ténylegesen módosított bit indexét a szám alsó 26 bitje adja. Így a bit módosítását a szitatábla ténylegesen elvégzi a memóriában, de ez eredmény

bitjeiből nem lehet megállapítani, hogy melyik szám prím.

Mindegyik szita megvalósítása valamilyen formában eltárolja a már megtalált prímeket, de csak a szitált szegmens végének négyzetgyökéig veszik azokat figyelembe. A sziták a prímek tárolását a PrimitiveList osztály használatával oldják meg, az elemek csoportosítását a listán belüli helyük adja.

Az edénysoron alapuló sziták belső edényeinek pillanatnyi mérete tág határok között mozog, azért a memóriaveszteség csökkentésére ezek ez edények kisebb, fix méretű edények láncolt listái. Az edénysor ezeket a listaelemeket feldolgozás után újrahasznosítja a szemétgyűjtés elkerüléséhez. A listaelemeket a Bucket osztály írja le.

A CacheOptimizedLinearSieve a prímek listáját a prímek nagysága szerint csoportosítja. A csoportosítás tömör reprezentációja miatt kényelmesebb ezt a csoportosítást akkor elvégezni, amikor már a prímek listája az összes prímet tartalmazza. Ezért a COLS szita 2³²-ig egy egyszerű listás eratoszthenészi szitaként viselkedik, és az azutáni első szegmens szitálásakor alakítja ki a csoportosítást, és vált át az optimalizált algoritmusra.

A sziták egyszerű hierarchiát alkotnak. A SegmentedSieve leszármazottai a prímek listáját a szitált szegmensek átnézésével állítják elő, és a listát eltárolják. Az EratosthenesianSieve típusú sziták a prímekkel úgy szitálnak, hogy a prím eltárolt utolsó többszörösét a prím kétszeresével növelik, amíg a többszörös a szegmensbe esik.

A sziták algoritmusai a 38 oldalon a "Sziták" szakaszban vannak részletesebben kifejtve. Az implementációk főbb jellemzői:

• TrialDivision: próbaosztás

• SieveOfAtkin: Atkin szitája

- Eratoszthenész szitájának implementációi:
 - SieveOfEratosthenes: a prímeket egy tömbben tárolja, és minden szegmens szitálásához minden prímmel próbál szitálni a szegmensben
 - QueueSieve: a prímeket bináris kupacban tárolja, szitáláskor a kupac elejét dolgozza fel, amíg az a szegmensbe esik.
 - CacheOptimizedLinearSieve: a prímeket kétszintű edényrendszerben tárolja, szitáláskor a szegmensbe eső elemek már edényekbe vannak válogatva, azokat csak be kell járni
 - SimpleBucketSieve: a prímeket a QueueSieve-hez hasonlóan egy elsőbbségi sorban tartja nyilván, az elsőbbségi sor egyre nagyobb intervallumokat lefedő edények listája. Ez a szita a szegmensmérettől függetlenül

- minden számon sorban halad végig a szitatáblában, és arról egyetlen menetben dönti el, hogy többszöröse-e valamelyik prímnek.
- Bucket1Sieve: az edénysoron alapuló szita felgyorsítása a COLS 0. "körével", a szegmensek méreténél kisebb prímeket a sortól külön, egy tömbben tárolja. Ezek a kis prímek minden szegmensben szitálnak, felesleges lenne a sorból minden szegmensnél kivenni, majd visszahelyezni ezeket.
- BucketNSieve: a Bucket1Sieve további gyorsítása, az edénysor számrendszerének alapját megnövelve a prímek részleges rendezését finomítja.

gui.ui

Ebben a csomagban a Swing használatát megkönnyítő osztályok vannak.

A program legtöbb művelete hosszú időt vesz igénybe, és a felhasználó az elindítása után már nem tudja befolyásolni. A gui.ui.progress alcsomag az ilyen lassú folyamatok visszajelzését segíti. A Progress interfészen keresztül egy folyamat százalékban visszaadhatja, hogy hol tart. A Progress.subProgress() egy új Progress példányt hoz létre, ami a szülő egy részfolyamatát reprezentálja, ezzel részeljárások elöl elfedhető a teljes megoldásban elfoglal helyük. Az interfésznek két implementációja adott, parancssorhoz a PrintStreamProgress, és a grafikus GuiProgress. Mindkét megvalósítás ügyel arra, hogy gyakori státuszfrissítés esetén a megjelenítés ne tartsa fel a ténylegesen elvégzendő műveletet.

A lassú folyamatok megvalósításának másik segédosztálya a GuiProcess. Ez az absztrakt osztály megszervezi a grafikus felületen a háttérfolyamatok futtatását. A Swing szál feltartása helyett a lassú művelet háttérben futtatható részét egy külön szálban futtatja, a műveletet a background() metódusában kell megvalósítani. A background() függvény lefutása után a foreground() metódust a Swing szálban hívja meg, az eredmény itt jeleníthető meg. Az eredmény átadása a két szál között az osztály megvalósítására van bízva, a szálak szinkronizálásának megkönnyítésére a background() metódusból visszatérés garantáltan happens-before relációban van a foreground() meghívásával. A GuiProcess a background() futásához egy GuiProgress példányt is létrehoz, amin keresztül a háttérfolyamat vissza tudja jelezni, hogy hol tart.

Grafikus megjelenítés

A grafikus program fő ablakát a gui. Gui osztály írja le. A program ablakai egy közös Session objektumon keresztül tartanak fenn szálakat a háttérfolyamatok futtatására. Ez az objektum számon tartja a nyitott ablakok számát, és az utolsó becsukásával a háttérszálakat szabályosan leállítja.

Parancssor

A gui program legtöbb művelete parancssorból is indítható. A parancssori műveleteket írják le a gui.Command.Descriptor osztály példányai. A gui.Main.main() a program indítási paramétereit ezekkel a leírókkal összevetve választja ki a futtatandó parancsot. A leíró a parancs belépési pontja mellett a megengedett argumentumok listáját tartalmazza. A parancs kiválasztásához a tényleges és elvárt argumentumok meg kell egyezzenek. Az argumentum leírásában található reguláris kifejezéssel a main() szintaktikailag ellenőrzi a tényleges argumentumokat, a szemantikai helyesség ellenőrzése minden parancs saját feladata.

Adatbázis műveletek

Az adatbázison három művelet végezhető, ezek implementációja a Database osztály info() metódusa, ami összegyűjti az adatbázisban tárolt szegmensek információit, az importAggregates() a megadott és az adatbázis összesítőfájlát összefésüli, és a reaggregate() az új szegmensfájlokat összesíti. Ez a két művelet a szegmens és összesítőfájl segédosztályait használja, az összefésülő rendezéshez hasonlóan ezek egyetlen menetben oldják meg a feladatot.

Egyik művelet sem interaktív, a paraméterek megadása és az eredmény visszajelzése is a legegyszerűbb megoldásokat használja grafikusan és parancssorban is. Ezek megvalósítása a gui.io.command csomagban található.

A sziták eredményeinek ellenőrzése

A szegmensfájlok és a sziták ellenőrzése a gui.check csomagban van megvalósítva. Mindkettő parancssorból és grafikusan is indítható, az adatbázis műveletekhez hasonlóan a paraméterek bekérése és az eredmény megjelenítése a legegyszerűbb eszközöket használja.

Mindkét művelet az ellenőrzéseket szegmensenként végzi. Az összehasonlításhoz a ReferenceSegment osztály állítja elő a referenciának vett szitatáblát. A szitatáblát a ReferenceSegment.SIEVE példány Eratoszthenész szitával készíti el, a ReferenceSegment.TEST az erős pszeudoprím teszttel.

A pszeudoprím teszt a referenciaként használt szegmens előállításához a szegmens minden számára végrehajtja a determinisztikus Miller-Rabin pszeudoprímtesztet. Ehhez szükséges a módszer teljességét 2⁶⁴-ig garantáló alapot választani. A módszer leírását és az alapot [7]-ben lehet megtalálni.


A CheckSegments.checkSegments() metódus végzi a szegmensek ellenőrzését, a kiválasztott szegmensek beolvasását, a referencia generálását, és az kettő összehasonlítását. A CheckSieve.checkSieve() metódus ehhez hasonlóan működik. Az

ellenőrizni kívánt szegmenseket a kiválasztott szitával állítja elő, és az ellenőrző szegmensek előállítását mindig a ReferenceSieve.SIEVE-vel végzi.

Grafikon ábrázolása

A grafikonok megjelenítése a program egyetlen interaktív része, ennek kezelésére a modell-nézet-vezérlő mintát használja. A modell a megjelenítendő minták és függvények, valamint a grafikon megjelenítendő intervalluma. A nézet a sztenderd Swing komponenseket használja. A vezérlő a gui segédosztályaira épít.

A modell alapján a megjelenítéshez szükséges grafikus utasítások előállítása időigényes. A mintákat és a függvényeket pixel széles intervallumokon mintavételezve határozza meg a képernyő egy oszlopához tartozó minimum és maximum értékeket. Az interaktivitás érzésének fenntartásához az oszlopokra bontást a program egy háttérszálban végzi, és közben a részeredményeket rendszeresen átadja a nézetnek megjelenítésre. A felhasználó a háttérszámítások közben a modellt módosítva az addigi előszámításokat elveszíti, és egy új háttérszál indul.



35

Modell

A modell osztályai a gui.graph csomagban vannak. A modellt a Graph osztály írja le. Ez egy nem módosítható konténerosztály, az ábrázoláshoz szükséges összes paramétert tartalmazza:

- a mintákat, ezeket a Sample osztály írja le
- a függvényeket, ezeket a Function osztály írja le
- a grafikon ábrázolására használható képernyőrész szélességét és magasságát pixelekben
- a grafikon megjelenített részét, amit a mintatér koordináta rendszerében lehet megadni egy téglalap sarkaival
- a megjelenítéshez használt színeket

A RenderedGraph osztály tartalmazza a minták és függvények oszlopokra bontását. A Graph osztályhoz hasonlóan ennek az osztálynak a példányai se módosíthatóak. A RenderedGraph tartalmazza a hozzá tartozó Graph referenciáját is, ezzel mindig ellenőrizhető, hogy a két modell objektum egymáshoz tartozik.

A RenderedSample osztály írja le az oszlopok mintavételezésének eredményét. Függvényből származó oszlopminták egybefüggő, diszjunkt intervallumonként csoportosítva vannak a RenderedInterval osztály segítségével. Ha az oszlopminta mintából származik, akkor egyetlen RenderedInterval példányba kerül az összes oszlopa.

Ezeknek az osztályoknak a módosíthatatlansága megkönnyíti a helyes többszálú feldolgozást. Egy kész objektumot egy szál sem fog megváltozni látni, és a referenciák megjegyzésével könnyen követhető, hogy melyik a legújabb modell.

A grafikon oszlopokra bontását a GraphRenderer osztály vezérli. A minták felbontásához pixel széles oszlopok intervallumán megkeresi a legkisebb és a legnagyobb mintaértéket, és az összes ilyet egyetlen RenderedInterval-ba teszi. A mintákat a nézet minden kitöltött oszlop között összeköti egy vékony egyenessel. Ahhoz, hogy a megjelenítés szélein túlra is be legyen húzva ez az egyenes, az oszlopmintába a megjelenített intervallumtól balra és jobbra eső mintaelem is bekerül.

Függvények előkészítésénél az eljárás ehhez nagyon hasonló. Az oszlop minimum és maximum értékét pontos módszer helyett mintavételezéssel határozza meg. Az oszlop intervallumában több, egyenletes távolságra lévő ponton kiértékeli a függvényt, és ezekből határozza meg az értékeket. A függvény oszlopmintájában az intervallumok összefüggőek, a függvény az intervallum legelső oszlopának bal szélétől a legutolsó oszlop jobb széléig értelmezve van. A nézet ennek megfelelően az értelmezett intervallumok közötti szakaszokon semmit nem rajzol ki.

A GraphRenderer a nézettel a CheckAndPost interfészen keresztül kommunikál a pontos nézetimplementáció ismerete nélkül. A check() metódussal le tudja ellenőrizni, hogy a legújabb modell az-e, amit éppen feldolgoz. A checkAndPost() metódussal az ellenőrzés után az addig elkészült részeredményt tovább is adja megjelenítésre. Ha a modell már elavult, a check() és checkAndPost() metódusok egy RendererDeathException-t dobnak, és a GraphRenderer hibajelzés nélkül leáll. Ez csak akkor fordulhat elő, ha egy másik szálon már dolgozik egy új GraphRenderer, ami előállítja az új megjeleníthető modellt.

Vezérlő

A grafikon megjelenítésének ablaka a Plotter osztály. A vezérlő ennek az ablaknak az eseménykezelői, amik a modell módosításán keresztül tudják módosítani a megjelenített grafikont. A modellen végezhető műveletek:

- a grafikon megjelenített részének mozgatása, nagyítása, kicsinyítése
- minta hozzáadása
- minta törlése
- minta közelítése
- közelítő függvény törlése

Ezek megvalósítására a program a Swing sztenderd komponenseit használja.

A mintát a modellhez adni három forrásból lehet. Az adatbázis összesített statisztikáiból, ezek előállítása az Aggregates osztály feladata. Be lehet tölteni mintát CSV fájlból, ezt a LoadSampleProcess oldja meg. Vagy meg lehet mérni egy szita futási idejét. A futási idő mérése a parancssorból indítható mérést használja, a MeasureSieve ablak a mérés paramétereinek megadására szolgál.

A minta közelítésének számítási részét a gui.math csomag végzi. Az elemi függvények kiválasztása a FunctionSelector ablakban lehetséges. Elemi függvényt JavaScript nyelven a CustomFunctionDialog ablakban lehet megadni.

A GraphPlotter komponens a grafikon egérrel történő mozgatásáról, nagyításáról, vagy az ablak méretének változásáról eseményeket küld a vezérlésnek, így a nézet csak a vezérlésen keresztül módosítja a modellt.

Nézet

A nézetet a **GraphPlotter** osztály reprezentálja. A két részből álló előkészített modell megjelenítése a grafikus vezérlőutasítások kiadásából áll.

Ennek a komponensnek a graph adattagja tartalmazza a legújabb modell értéket, a vezérlés, az előkészítés, és a megjelenítés ezen keresztül kommunikál. A modell módosításakor a GraphPlotter objektum a graph adattag cseréjével biztosítja, hogy a régi modellre vonatkozó háttérszál leáll, és elindítja az új modell oszlopra bontását. Az előkészített modellről a CheckAndPost eseménykezelőjén keresztül értesül, aminek hatására ütemezi az új grafikon kirajzolását. A tényleges kirajzolásnál még egyszer ellenőrzi, hogy a grafikon a komponens tényleges méretére készült el, majd a már elkészült grafikon-részeket kirajzolja.

Sziták

A gui program tartalmazza Eratoszthenész szitájának több megvalósítását. Ezek az implementációk mind szegmentáltak, azaz csak egy rövidebb intervallumon szitálnak, és annak befejezéséig nem kezdenek bele új intervallumba. Egy intervallum szitáláshoz szükséges az intervallum végének négyzetgyökéig a prímek listája. A prímeket ismerve maradékos osztással meghatározható, hogy melyik a legkisebb többszörösük, ami legalább akkora, mint az intervallum kezdete, és onnantól összeadással az intervallum végéig meghatározható a többi többszörösük. A 3.1 algoritmus ezt írja le.

```
Algoritmus 3.1 Az [u, v) intervallum szitálása
```

```
1: legyenek a számok az [u, v) intervallumban megjelöletlenek
 2: for p \in \{\text{primek}\sqrt{v-1}\text{-ig}\}\ \mathbf{do}
         for f \leftarrow \max\{p^2, p\left\lceil \frac{u}{p}\right\rceil\}; v > f; f \leftarrow f + p do
 3:
             legven f megielölve
 4:
 5:
         end for
 6: end for
 7: for f \in [u, v) do
         if f nincs megjelölve then
 9:
              f prím
         end if
10:
11: end for
```

Ha több egymás utáni intervallumot kell szitálni, akkor minden prímhez eltárolható, hogy melyik pozícióban fog legközelebb szitálni. Ezzel az osztások időbeli költsége tárhely költségre váltható. A legegyszerűbb megoldás a prím-pozíció párok tárolása egy tömbben. A 3.2 algoritmus az [u, v) intervallum szitálását írja le, ahol v = u + kd. Az algoritmus k darab d hosszú részintervallumot szitál.

A gui programban "Eratoszthenész szitája" ezt az algoritmust valósítja meg. Ezzel a módszerrel a program minden rövid szegmensben a tömb minden elemét sorra veszi, azokat is, amik a szegmensben nem szitálnak. A többi implementált eratoszthenészi szita összetettebb struktúrákkal próbálja kiválasztani a ténylegesen

Algoritmus 3.2 Az [u, v) intervallum szitálása, v = u + kd

```
1: legyen t egy tömb
 2: s \leftarrow 0
                                                                              ⊳ a tömb elemeinek száma
 3: for p \in \{\text{prímek}\sqrt{v-1}\text{-ig}\}\ \mathbf{do}
         t[s] \leftarrow (p:p,f:\max\{p^2,p\left\lceil\frac{u}{p}\right\rceil\})
 4:
 5:
 6: end for
    for \ell \leftarrow 1, u' \leftarrow u, v' \leftarrow u + d; k \ge \ell; \ell \leftarrow \ell + 1, u' \leftarrow u' + d, v' \leftarrow v' + d do
         legyenek a számok az [u', v') intervallumban megjelöletlenek
 8:
         for i \in [1, s] do
 9:
              for ; v' > t[i].f; t[i].f \leftarrow t[i].f + t[i].p do
10:
                   legyen t[i].f megjelölve
11:
              end for
12:
         end for
13:
         for f \in [u', v') do
14:
              if f nincs megjelölve then
15:
                   f prím
16:
              end if
17:
         end for
18:
19: end for
```

szitáló elemeket. A többi implementált szita prioritásos sort használ az elemek részleges rendezéséhez, és sor elejének feldolgozásával választja ki a szegmensben szitáló elemeket. A bináris kupac és az edénysort használó szita mellett a Cache Optimalizált Lineáris Szita is soron alapul.

Prioritásos sorok

A prioritásos soron alapuló szita algoritmusa nagyon hasonló a 3.2 algoritmushoz. A tömbelemek sorban feldolgozása helyett a sor elejét addig veszi ki, amíg az az éppen szitált szegmensbe esik. Ezekkel az elemekkel a szitálást elvégzi a szegmensben, majd a sorba visszahelyezi, már az új, mostani szegmensnél nagyobb pozícióval. Az elemek sorrendjét a legközelebbi szitált pozíció határozza meg, a sor eleje az éppen szitált szegmenshez legközelebbi elem. Az elemek sorrendjénél a szegmenseken belüli sorrend vizsgálata felesleges. A prioritásos soron alapuló szitálást a 3.3 algoritmus írja le, a sor adatszerkezet meghatározása nélkül.

Algoritmus 3.3 Az [u, v = u + kd) intervallum szitálása, prioritásos sorral

```
1: legyen q egy üres sor
 2: for p \in \{\text{prímek}\sqrt{v-1}\text{-ig}\}\ \mathbf{do}
         hozzáad<br/>(q,(p:p,f:\max\{p^2,p\left\lceil\frac{u}{p}\right\rceil\}))
 3:
 4: end for
 5: for \ell \leftarrow 1, u' \leftarrow u, v' \leftarrow u + d; k \ge \ell; \ell \leftarrow \ell + 1, u' \leftarrow u' + d, v' \leftarrow v' + d do
         legyenek a számok az [u', v') intervallumban megjelöletlenek
 6:
         while v' > \min(q).f do
 7:
              (p, f) \leftarrow \text{eltávolít-min}(q)
 8:
              for ; v' > f; f \leftarrow f + p \text{ do}
 9:
10:
                   legyen f megjelölve
              end for
11:
              hozzáad(q,(p,f))
12:
         end while
13:
         for f \in [u', v') do
14:
              if f nincs megjelölve then
15:
                   f prím
16:
              end if
17:
         end for
18:
19: end for
```

A tényleges megvalósítás az eltávolít-hozzáad sorműveletpár helyett a helyben módosítást és a struktúra invariánsának visszaállítását is választhatja.

A gui program szitái közül ezt az algoritmust követi az edénysor szita, a bináris kupac szita, és a COLS körkörös listája is. A bináris kupac szitánál az eltávolítás-hozzáadás és a helyben javítás között a felhasználó választhat.

Edénysor

A edénysor egy monoton prioritásos sor. Minden állapotához tartozik egy érték, a sor aktuális pozíciója, aminél kisebb vagy egyenlő pozíciójú értéket a sor nem tartalmazhat, és a sor pozíciója nem csökkenhet. A sor pozíciójának megnövelése a sor elejének eltávolításával is együtt jár.

A sor edények egy végtelen sorozatát is tárolja, a sor elemei ezekbe az edényekbe kerülnek. Egy eltárolt elem helyét az edények között az elem pozíciójának és a sor aktuális pozíciójának távolsága határozza meg. Két szám távolságát egy számrendszerben két érték határozza meg, a legnagyobb helyiérték, amiben eltérnek a számjegyeik, és a nagyobbik szám számjegye ezen a helyiértéken.

Legyen $a \in \mathbb{N}$, a > 1 a sor számrendszerének alapszáma. Az x szám i-edik számjegyét a alapú számrendszerben jelölje x_i . Legyen h(x, y) a legnagyobb helyiérték,

ahol x és y eltér. A sor által használt d(x,y) távolságfüggvény az y-x eltérés nagyságrendjének finomítása a jobb argumentum releváns számjegyével.

$$x = \sum_{i=0}^{\infty} x_i a^i \ (i \in \mathbb{N}_0, x_i \in \mathbb{N}_0, x_i < a)$$
 (3.1)

$$h(x,y) = \max\{i \in \mathbb{N}_0 | x_i \neq y_i\} \ (x,y \in \mathbb{N}_0, x < y)$$
 (3.2)

$$d(x,y) = (a-1)h(x,y) + y_{h(x,y)} - 1$$
(3.3)

Kettes számrendszerben a távolság logaritmussal és a bitenkénti kizáró-vagy művelettel is megadható.

$$d(x,y) = h(x,y) = \lfloor \log_2(x \oplus y) \rfloor$$

Legyen q egy edénysor

- a alapszámmal
- $p(q) \in \mathbb{N}_0$ a q sor pozíciója
- b(q,i) a q sor i. edénye $(i \in \mathbb{N}_0)$
- $p(r) \in \mathbb{N}$ a q sor egy lehetséges r elemének pozíciója.

Ekkor a q sor invariánsa:

$$\forall r \in q :$$

$$p(q) < p(r)$$

$$\forall i \in \mathbb{N}_0 : r \in b(q, i) \iff i = d(p(q), p(r))$$

$$\forall r \notin q : \forall i \in \mathbb{N}_0 : r \notin b(q, i)$$

Új sor létrehozásához az edények listáját kell létrehozni, a sor kezdő pozíciója bármi lehet. Új elemet a sorhoz a távolságfüggvény kiértékelése után az elem edénybe szúrásával lehet adni, az új r elem az b(q, d(p(q), p(r))) edénybe kell kerüljön. Ez a művelet az invariánst fenntartja.

A sor pozíciójának eggyel megnövelésével (Algoritmus 3.4) a sor invariánsa kétféleképpen válhat hamissá:

- egy elem pozíciója és a sor pozíciója egyenlő lesz. A pozíció növelése művelet ezeket az elemeket a sorból eltávolítja, és a művelet eredményeként visszaadja.
- az elem és a sor pozíciójának távolsága csökken. Az invariáns visszaállításához a művelet ezeket az elemeket áthelyezi az új távolság szerinti edénybe.

A sor elejének eltávolítsa az edénysornál tetszőleges számú elemet távolíthat el a sorból, és nem üres sor esetén is előfordulhat, hogy a sor elejének eltávolítása nem ad vissza elemeket.

Algoritmus 3.4 A q edénysor pozíciójának növelése és az elejének eltávolítása

```
1: function ELTÁVOLÍT-MIN(q)
         \ell \leftarrow \ddot{\text{u}}res lista
 2:
         i \leftarrow d(p(q), p(q) + 1)
 3:
         p(q) \leftarrow p(q) + 1
 4:
 5:
         while b(q, i) nem üres do
             r \leftarrow \text{eltávolít}(b(q, i))
 6:
             if p(r) = p(q) then
 7:
                  hozzáad(\ell, r)
 8:
             else
 9:
                  hozzáad(b(q, d(p(q), p(r))), r)
10:
             end if
11:
12:
         end while
         return \ell
13:
14: end function
```

Az edénysor elejét ezzel az adatstruktúrával nem lehet hatékonyan lekérni az elemek eltávolítása nélkül.

Az edénysort használó szita esetén a sor elemei a prím-pozíció párok. A sor pozícióját a szegmens végéig növelve pontosan a szegmensben szitáló prímek kerülnek ki a sorból, a sor elejének lekérdezésére nincs szükség.

Ha a szegmensek hossza egy szám, akkor a prímek azok a sorpozíciók, amelyek elérésével a sor pozíciójának növelése nem távolít el elemet. A buckets-simple szita a felhasználó által megadott szegmensmérettől függetlenül így működik, a számokról sorban, egyetlen menetben dönti el, hogy melyik prím.

Funkcionális megvalósítás

Az edénysoron alapuló szitára tisztán funkcionális megvalósítás adható. Az edénysor műveleteit láncolt listákkal számjegyenként ábrázolt számok összeadására lehet visszavezetni.

Az x+y összeadás elvégzésével a h(x,x+y) és a d(x,x+y) is kiszámítható, h(x,x+y) a helyiérték, ahol összeadás közben a kisebbik szám számjegyei és az átvitel is elfogy. A d(x,x+y) meghatározásához az eredményből még a h(x,x+y) helyiértéken lévő számjegyet is ki kell olvasni. A számok láncolt listával ábrázolásával az x+y kiszámítása $\theta(h(x,x+y))$ műveletet igényel.

Az edénysor pozíciójának növeléséért felelős algoritmus a kiválasztott edény újrarendezését számjegyenként végzi egy olyan számítási modellben is, ahol számok összeadása konstans idejű. Ha r a q sor eleme, akkor az elem a sorból kikerüléséig még h(p(q), p(r)) edényt bejárhat.

Az edénysort szitálásra használva az új elemek pozíciója mindig p(q) + b, ahol b prím. Ekkor a számjegyenkénti összeadás miatt h(p(q), p(q) + b) legalább akkora, mint b legnagyobb nem 0 helyiértéke, $\lfloor \log_a b \rfloor$.

A CD mellékleten megtalálható az edénysor szita egy Haskell megvalósítása a hs könyvtárban. A program kettes számrendszerű edénysort használ, és a szitálás minden műveletét bit-listák feldolgozására vezeti vissza.


Sebesség

A generator program az edénysoron alapuló szita optimalizált változata. Az optimalizálások közül a szegmensméret, és a sor számrendszerének alapja tág határok között megválasztható. A measure-generator szkript a szegmensméret és számrendszer választások sebességét méri meg. Mindkét paramétert 2 hatványainak választja, a szegmensméretet 2¹⁶-tól 2²⁴-ig, a számrendszert 2¹-től 2⁸-ig.

3.1. táblázat. A generator futási ideje (ns), szitált intervallum $[2^{63}, 2^{63} + 2^{34})$

szegmens / alan	2^{1}	2^2	2^4	28
szegmens / alap		2		<u> </u>
2^{16}	3.17×10^{11}	2.30×10^{11}	1.49×10^{11}	1.06×10^{11}
2^{17}	2.73×10^{11}	2.13×10^{11}	1.34×10^{11}	9.58×10^{10}
2^{18}	2.35×10^{11}	1.78×10^{11}	1.22×10^{11}	8.87×10^{10}
2^{19}	2.06×10^{11}	1.68×10^{11}	1.14×10^{11}	8.73×10^{10}
2^{20}	1.79×10^{11}	1.44×10^{11}	1.06×10^{11}	8.36×10^{10}
2^{21}	1.57×10^{11}	1.33×10^{11}	9.80×10^{10}	7.92×10^{10}
2^{22}	1.40×10^{11}	1.18×10^{11}	9.31×10^{10}	7.55×10^{10}
2^{23}	1.34×10^{11}	1.18×10^{11}	9.09×10^{10}	7.63×10^{10}
2^{24}	1.67×10^{11}	1.52×10^{11}	1.25×10^{11}	1.15×10^{11}

3.3. ábra. A generator futási ideje (ns), szitált intervallum [2⁶³, 2⁶³ + 2³⁴) $\cdot 10^{-6}$



Az edénysor helyessége

Egy szám számjegyenkénti felírásából, és h definíciójából(3.2) következik, hogy

$$x_{h(x,y)} < y_{h(x,y)} \ (x, y \in \mathbb{N}_0, x < y)$$
 (3.4)

A sor pozíciójának pontosan eggyel növelésének következménye, hogy a legnagyobb megváltozott helyiértéken eggyel nő a számjegy, és az összes kisebb helyiértéken a legnagyobb számjegy 0-ra vált. Ha x = p(q), y = p(q) + 1, d' = d(x, y), k = h(x, y), akkor

$$x_k + 1 = y_k \tag{3.5}$$

$$\forall i \in \mathbb{N}, i > k : x_k = y_k \tag{3.6}$$

$$\forall i \in \mathbb{N}, i < k : x_k = a - 1 \text{ \'es } y_k = 0 \tag{3.7}$$

A sor elejének eltávolítása algoritmus helyessége következik abból, hogy a d'-nél kisebb indexű edények üresek, a d'-nél nagyobb indexű edények elemeinek távolsága nem változik a sor pozíciójának növelésével, és a d' edény elemeit az algoritmus újrarendezi. A helyesség bizonyításához a következő két állítást kell bizonyítani:

$$\forall i \in \mathbb{N}_0, i < d' : b(q, i) = \emptyset \tag{3.8}$$

$$\forall i \in \mathbb{N}_0, i > d' : \forall r \in b(q, i) : i = d(p(q), p(r)) = d(p(q) + 1, p(r))$$
(3.9)

A (3.8) bizonyításához tegyük fel indirekt, hogy $\exists i < d' : \exists r \in b(q, i)$. Legyen k' = h(p(q), p(r)). Az indirekt feltevés szerint

$$d(p(q), p(r)) = i < d' = d(p(q), p(q) + 1)$$

Ha $k' \neq k$, akkor (3.3) miatt k' < k, de (3.4) és (3.7) ellentmondáshoz vezet, $p(r)_{k'} \in \mathbb{N}_0$ két egymás követő egész között lenne:

$$a-1 = p(q)_{k'} < p(r)_{k'} < a$$

Ha k' = k, akkor i < d' és (3.3) miatt $p(r)_k < (p(q) + 1)_k$. Ekkor (3.4) és (3.5) ellentmond egymásnak, $p(r)_k$ értéke ekkor is két egymást követő egész közé kéne essen:

$$p(q)_k < p(r)_k < (p(q) + 1)_k = p(q)_k + 1$$

Tehát az indirekt feltevés ellentmondáshoz vezet, azaz (3.8) igaz, a d'-nél kisebb indexű edények üresek.

Legyen $i \in \mathbb{N}_0, i > d', r \in b(q, i), k' = h(p(q), p(r))$. Ha k' = k, akkor i > d' és (3.3) miatt

$$i = (a-1)k + p(r)_k - 1$$
$$d' = (a-1)k + (p(q)+1)_k - 1$$
$$p(q)_k < (p(q)+1)_k = p(q)_k + 1 < p(r)_k$$

amiből következik (3.2) és (3.6) miatt, hogy

$$h(p(q), p(q) + 1) = h(p(q), p(r)) = h(p(q) + 1, p(r)) = k$$

Ebből (3.3) alapján

$$d(p(q), p(r)) = (a-1)k + p(r)_k - 1 = d(p(q) + 1, p(r))$$

Ha $k \neq k'$, akkor 3.3 szerint k < k'. (3.2) és (3.6) szerint

$$p(q)_{k'} = (p(q) + 1)_{k'} \neq p(r)_{k'}$$

$$h(p(q), p(r)) = k' = h(p(q) + 1, p(r))$$

$$d(p(q), p(r)) = (a - 1)k' + p(r)_{k'} - 1 = d(p(q) + 1, p(r))$$

Ezek alapján 3.9 igaz, az elem távolsága nem változik a sor elejéhez képest.

A program ellenőrzése

A megoldás szitáinak ellenőrzése a gui program feladata. Az init és generator program szegmensfájlai, és a gui szitáinak kimenetei is a ReferenceSegment osztály szitájával összehasonlíthatóak. Ezen keresztül a sziták kimenetének egyenlősége szúrópróbaszerűen ellenőrizhető. Ezeket az időigényes ellenőrzéséket végzi el a test-sieves szkript minden szitával több intervallumon. A teszt ellenőrzéséhez a szkript egy szándékosan hibás szegmens, és egy hibás szita ellenőrzését is elvégzi.

A gui program gui.math és gui.util csomagjaira a program összes többi része épít, az adatbázis műveletek, a sziták, és a megjelenítés is. Erre a két csomagra a JUnit keretrendszerrel és a JaCoCo lefedettségmérővel teljes lefedettségű egységtesztek készültek.

Az összesített statisztikák ellenőrzésére a test-prime-counts szkript a prímek számát a samples/test/prime-counts.csv fájlba írja az adatbázis alapján kettő hatványai helyeken, míg a test-max-prime-gaps szkript a maximális prímhézagokat a samples/test/max-prime-gaps.csv fájlba menti. Ezek a publikált értékekkel[3][4] összevethetőek. Ezeket a fájlokat a gui program gui.test csomagjának osztályai készítik el. A program tesztelésénél ez a két statisztika 2^{47} ($\approx 1.4 \times 10^{14}$)-ig egyezett.

A minták és közelítő függvények megjelenítésének tesztelése ismert grafikonú mintákkal való összevetéssel történt. Táblázatkezelő programokkal, mint például a LibreOffice, formula alapján generált minták grafikonja ábrázolható, és a gui program által olvasott CSV formátumú fájlba menthető. A formulákkal véletlenszerű zaj is hozzáadható a mintához. A samples/test/graph könyvtárban megtalálható néhány táblázatminta a teszteléshez.

Legkisebb négyzetek módszere

A legkisebb négyzetek módszerének megvalósítása a mátrixműveletek pontosságát két paraméterrel tudja szabályozni, a mátrixszorzás összegzéseit három különböző algoritmussal lehet végezni, és a lineáris egyenletrendszereket meg lehet oldani QR felbontással, és Gauss-eliminációval részleges sorcserével és teljes sor és oszlop cserével. Ezeknek a paramétereknek a megválasztása a tesztek alapján sem egyértelmű.

A test-measure-sums közelítések pontosságáról készít statisztikákat három változóban, és az eredményt a samples/test/measure-sums.csv fájlba menti. A három váltózó:

- az összegzést tömbbel, kupaccal, vagy egyetlen változóval végezze
- az egyenletrendszerek megoldását QR felbontással, részleges vagy teljes Gausseliminációval végezze

• x szerint rendezett-e a minta.

A három paraméter mindegyik lehetséges értékéhez a mérés elemi függvények alapján egy mintát generál, majd ezt a mintát ugyanezekkel az elemi függvényekkel közelíti. Egy paraméter-kombinációhoz az összes közelítés négyzetes eltérését, és a közelítés idejét összesíti. A minták generálásához használt elemi függvények a MeasureSums osztályból kiolvashatóak.

A mérés eredményéből (3.2 táblázat) látszik, hogy a kiválasztott minták közelítésénél:

- a legkisebb hibát okozó választás a kupac összegzés teljes cserét végrehajtó
 Gauss-eliminációval
- a kupac összegzés tízszer annyi időt vesz igénybe, mint a másik két összegzés
- az egy változóban összegzés hibája több nagyságrenddel nagyobb, mint a másik két összegzés hibája
- a sor és oszlop csere nem számít egy változóban összegezve, a teljes csere tömbben összegezve valamivel pontosabb, és a kupac összegzésnél a teljes csere lényegesen pontosabb eredmény ad
- a QR felbontás általában nagyobb hibát eredményez, mint a Gauss-elimináció
- a kupac összegzés a minta rendezettségére nem érzékeny
- a rendezetlen minta összegzése a változóval és tömbbel pontosabb, mint a rendezett.

Ezek alapján a program a közelítésekre a kupac alapú összegzést használja, és a lineáris egyenletrendszerek megoldására Gauss-eliminációt használ teljes sor és oszlopcserével, ezt a felhasználó nem tudja megváltoztatni.

3.2. táblázat. Numerikus algoritmusok összehasonlítása

Összegzés	LER-m.o.	Rendezett	$\sum \mathbf{hiba}^2$	Idő (ns)
változó	részleges G.E.	igen	2.53×10^{25}	1.27×10^{9}
		nem	4.24×10^{23}	1.83×10^{9}
	teljes G.E.	igen	2.53×10^{25}	1.28×10^{9}
		nem	4.21×10^{23}	1.84×10^{9}
	QR	igen	9.47×10^{24}	1.34×10^{9}
		nem	2.58×10^{23}	1.83×10^{9}
tömb	részleges G.E.	igen	2.62×10^{20}	1.46×10^{9}
		nem	9.75×10^{19}	2.43×10^{9}
	teljes G.E.	igen	1.87×10^{20}	1.53×10^{9}
		nem	6.76×10^{19}	2.37×10^9
	QR	igen	6.41×10^{23}	1.61×10^{9}
		nem	3.63×10^{20}	2.43×10^{9}
kupac	részleges G.E.	igen	1.12×10^{21}	1.40×10^{10}
		nem	1.12×10^{21}	1.76×10^{10}
	teljes G.E.	igen	3.12×10^{19}	1.39×10^{10}
		nem	3.12×10^{19}	1.77×10^{10}
	QR	igen	1.30×10^{22}	1.44×10^{10}
		nem	1.30×10^{22}	1.75×10^{10}

4. fejezet

Irodalomjegyzék

- A. O. L. Atkin, D. J. Bernstein: Prime sieves using binary quadratic forms, Mathematics of Computation, Volume 73 (2004) 1023–1030
- [2] A. Járai, E. Vatai: Cache optimized linear sieve, Acta Univ. Sapientiae, Inform. 3,2 (2011) 205-223
- [3] Tomás Oliveira e Silva, Siegfried Herzog and Silvio Pardi: Empirical verification of the even Goldbach conjecture and computation of prime gaps up to $4 \cdot 10^{18}$, Math. Comp. 83 (2014), 2033-2060
- [4] Tomás Oliveira e Silva: Tables of values of pi(x) and of pi2(x), http://sweet.ua.pt/tos/primes.html, 2018.11.30.
- [5] Miller, Gary L.: Riemann's Hypothesis and Tests for Primality, Journal of Computer and System Sciences, 13 (3): 300–317 (1976)
- [6] David M. Bressoud: Factorization and Primality Testing, Springer Verlag, 1989, 0-387-97040-1
- [7] Wojciech Izykowski, Jim Sinclair: Deterministic variants of the Miller-Rabin primality test, https://miller-rabin.appspot.com/, 2018.11.30.
- [8] Csajbók Tímea, Farkas Gábor, Járai Antal, Járai Zoltán, Kasza János: Report on the largest known Sophie Germain and twin primes, Annales Universitatis Scientiarium Budapestinensis de Rolando Eötvös Nominatae Sectio Computatorica 26: pp. 181-183. (2006)